

LabClear 4.0.0-rc3 รายงานสถาปัตยกรรมเทคโนโลยี และ Agent Flow

วิชา 06048308 Intelligent Chatbot Development · Final Project
ผู้พัฒนา นายวัชรินทร์ บัวสอน (68076055) · นายศิริพล ศรีเฮงไพบูลย์ (68076060)

รุ่น 4.0.0-rc3 · branch `integration/labclear-4.0-rc1` · commit ที่ทดสอบ `3191f93` · วันที่ 10 ตุลาคม 2569

รายงานนี้อธิบายระบบตามโค้ดจริงของรุ่น 4.0.0-rc3 ทุกตัวเลขอ่านจากไฟล์ใน repository (ระบุไฟล์ไว้ในวงเล็บ) ไม่ใช่ค่าที่ออกแบบไว้ล่วงหน้า ส่วนที่ปิดอยู่หรือยังไม่ได้ทำระบุไว้ตรง ๆ ผลทดสอบทั้งหมดใช้ข้อมูลสังเคราะห์และตัวแทนโมเดล รุ่นนี้ยังไม่ได้ deploy และยังไม่ได้รันกับ Typhoon และ iApp จริง

1. สรุป


LabClear เป็นเว็บแอป FastAPI บริการเดียว บน Render ที่ส่งทั้งหน้าเว็บและ API แชนบอทตอบลูกค้าคลินิกตรวจสอบสุขภาพจากข้อมูลของร้านและคลังความรู้ที่เจ้าของอนุมัติ อ่านใบผลแล็บ และอธิบายค่าเทียบช่วงอ้างอิงที่พิมพ์บนใบเดียวกัน หลักการออกแบบมี 6 ข้อ

หลักการ	ความหมายในโค้ด
โมเดลเสนอ Python ตัดสิน	planner เสนอ action บทบาท และคำค้น แต่ได้เลือกบทบาท ตรวจสอบสิทธิ์ เรียกเครื่องมือ และสร้างตัวอย่างการจองเอง (<code>services/agent_tools.py</code> , <code>business_agent.py</code>)
ตอบจากหลักฐานเท่านั้น	ผู้เขียนอ้างได้เฉพาะรหัสหลักฐานที่ได้รับ ค่าและราคาถูกตรวจกับข้อมูลต้นทาง แล้ว reviewer ตรวจสอบอีกชั้น
Fail closed	ไม่มีผลตัดสิน ผู้ให้บริการขัดข้อง หรือคำตอบผิดรูปแบบ ระบบหยุดและแจ้งเหตุ ไม่แต่งคำตอบแทน

หลักการ	ความหมายในโค้ด
ค่าใช้จ่ายมีเพดาน	ทุกการเรียกโมเดลผ่านด้านเดียว: สวิตช์เครือข่าย เพดานจำนวนครั้ง บัญชีบาท และนโยบายเรียกเฉพาะบริการฟรี
คำขอมีขอบเขตเวลา	ทุกคำขอ AI มี deadline เดียวทั้งเส้นทาง heartbeat และจบด้วยเหตุการณ์สุดท้ายหนึ่งรายการเสมอ
ภาษาไทยก่อน	หน้าเว็บ ข้อความผิดพลาด และคำตอบเป็นภาษาไทยเป็นค่าเริ่มต้น สลับภาษาอังกฤษได้

2. ภาพรวมระบบ

ผู้ใช้มี 2 กลุ่ม คือ ลูกค้า (รวมผู้เยี่ยมชมที่ไม่ได้เข้าสู่ระบบ) และเจ้าหน้าที่หรือผู้จัดการ ทั้งสองกลุ่มเข้าถึงบริการ `labclear` บน Render ผ่าน HTTPS บริการนี้รัน Uvicorn หนึ่ง process เพราะเซตของผู้เยี่ยมชมเก็บในหน่วยความจำของ process ข้อมูลถาวรอยู่ใน PostgreSQL ส่วนภายนอกมี 3 กลุ่ม คือ ผู้ให้บริการ AI (Typhoon, iApp) ช่องทางจำลอง (LINE, การชำระเงิน) และหน้าเว็บทางการของโรงพยาบาลที่ลูกค้าเปิดเอง



ภาพที่ 1 สถาปัตยกรรมของ LabClear รุ่น 4.0.0-rc3 (สร้างจากโค้ดด้วย `scripts/build_diagrams.py`)

ภายในบริการแบ่งเป็น 4 โมดูลหลัก

โมดูล	หน้าที่	ไฟล์หลัก
ไปป์ไลน์แชต	safety, planner, บทบาท, typed tools, runtime skills, ผู้เขียน, การตรวจ, reviewer	<code>services/business_agent.py</code>
ตัวอ่านใบผล	แปลงไฟล์ใน process แยก, OCR, ตรวจเอกสาร, แปลงเป็นแถว, ให้ลูกค้ายืนยัน	<code>services/report_reader_v2.py</code> , <code>document_worker.py</code> , <code>document_render.py</code>

โมดูล	หน้าที่	ไฟล์หลัก
งานธุรกิจ	แคตตาล็อก การเปรียบเทียบ การจอง การชำระเงินจำลอง กล่องข้อความ ใบ เสนอราคา	<code>services/business_ops.py</code> , <code>business_store.py</code> , <code>business_plans.py</code>
หน้าผู้ดูแล แบบไม่ต้อง เขียนโค้ด	Company Harness, คลังความรู้ (PDF), ผู้ให้บริการ AI, บทบาทผู้ช่วย	<code>routers/harness_admin.py</code> , <code>knowledge_admin.py</code> , <code>ai_admin.py</code>

3. Tech stack

3.1 Runtime และไลบรารี

Python 3.12 (`.python-version`; Render ตั้ง `PYTHON_VERSION=3.12.10`) ไม่มี Dockerfile หรือ pyproject ทุกไลบรารีของ runtime ปักเวอร์ชันใน

`requirements.txt`

ไลบรารี	เวอร์ชัน	ใช้ทำอะไร
FastAPI	0.142.2	ASGI framework และ router (Starlette 1.7.0, Pydantic 2.14.0)
Uvicorn (standard)	0.54.0	ASGI server หนึ่ง process (<code>scripts/run_business.py</code>)
httpx	0.28.1	เรียกผู้ให้บริการ AI, Google OAuth token, Stripe sandbox
Jinja2	3.1.6	หน้าเว็บฝั่งเซิร์ฟเวอร์ (<code>templates/</code>)
pydantic- settings	2.15.0	ค่าตั้งทั้งหมดใน <code>config.py</code> พร้อมการตรวจสอบเขต
python-dotenv	1.2.4	อ่าน <code>.env</code> เฉพาะตอนรันเป็นบริการ
python- multipart	0.0.32	รับไฟล์อัปโหลด
Pillow	12.3.0	ตรวจและเข้ารหัสภาพใหม่ (ลบ metadata)
pypdfium2	5.14.0	แปลงหน้า PDF เป็นภาพ และภาพตัวอย่างของคลัง ความรู้

ไลบรารี	เวอร์ชัน	ใช้ทำอะไร
cryptography	50.0.2	Fernet เข้ารหัสข้อมูลที่จัดเก็บ
psycopg (binary)	3.2.10	ไดรเวอร์ PostgreSQL
reportlab	4.4.10	สร้าง PDF สรุปความรู้ในหน้าคั่นความรู้

3.2 หน้าเว็บ

หน้าเว็บเป็น Jinja templates กับ JavaScript ธรรมดา ไม่มี framework ฝั่ง client และไม่มี build step ของแอป ไลบรารีภายนอกทุกตัวเก็บในเครื่อง (`static/vendor/`): marked 15.0.12 แปลง Markdown, DOMPurify 3.4.16 กรอง HTML และ three.js 0.186.1 สำหรับภาพ 3 มิติหน้าแรก ฟอนต์ทั้งหมด host เอง: IBM Plex Sans Thai (เนื้อหา), Trirong และ Source Serif 4 (หัวเรื่อง), Geist และ Geist Mono ข้อความภาษาไทย 3,187 รายการสร้างจาก `i18n/*.json` ด้วย `scripts/build_i18n.mjs`

ไฟล์ JavaScript	หน้าที่
<code>workspace.js</code>	พื้นที่ลูกค้า <code>/app</code> และศูนย์บริการลูกค้า <code>/staff</code>
<code>stream.js</code>	ตัวอ่าน NDJSON ที่จัดประเภทผลลัพธ์ (สำเร็จ, หน้า proxy, JSON error, สตรีมขาด) และ watchdog
<code>turns.js</code>	วาดข้อความ ขั้นตอน และความล้มเหลวของแต่ละรอบสนทนา
<code>api.js</code>	client กลางที่ส่ง CSRF และ guest token
<code>dock.js</code>	ผู้ช่วยแบบ dock บนทุกหน้าเว็บสาธารณะ
<code>admin-harness.js</code>	หน้า Company Harness และคลังความรู้ของผู้จัดการ
<code>i18n.js</code> , <code>theme.js</code> , <code>site.js</code> , <code>motion.js</code>	ภาษา ธีมสว่าง/มืด การค้น การเปรียบเทียบ และการเคลื่อนไหว

3.3 เครื่องมือทดสอบ

pytest 9.1.1 (`requirements-dev.txt`), Playwright 1.56.1 สำหรับชุดเบราว์เซอร์ (`package.json`; แอปไม่ใช่ Node), nbformat และ ipykernel

สำหรับ notebook สาธิต (`requirements-eval.txt`) และ Tesseract สำหรับ OCR ตัวแทนในชุดทดสอบ OFFLINE เท่านั้น

4. การ deploy และ process

4.1 Render Blueprint

`render.yaml` มีบริการเดียวชนิด `web` ชื่อ `labclear` runtime Python แผน `free` ติดตาม branch `main` และ deploy อัตโนมัติทุก commit (`autoDeployTrigger: commit`) build ด้วย `pip install -r requirements.txt` เริ่มด้วย `python scripts/run_business.py` และตรวจสอบสุขภาพที่ `/ready`

ค่าตั้งใน render.yaml	ค่า	ความหมาย
<code>APP_ENV</code>	<code>production</code>	เปิดการตรวจของ production เช่น ต้องมี PostgreSQL
<code>BUSINESS_EXTERNAL_ENABLED</code>	<code>false</code>	LINE และ Stripe จริงปิด
<code>RUNTIME_SKILLS_ENABLED</code>	<code>true</code>	ใช้ runtime skills
<code>HOSPITAL_LINKS_ENABLED</code>	<code>true</code>	แสดงลิงก์แฟ้มเวชของโรงพยาบาล
<code>CHAT_DEADLINE_SECONDS / REPORT_DEADLINE_SECONDS</code>	<code>220 / 150</code>	deadline ต่อคำขอ
<code>STREAM_HEARTBEAT_SECONDS</code>	<code>10</code>	ระยะ heartbeat
<code>AI_MAX_IN_FLIGHT / OCR_MAX_IN_FLIGHT</code>	<code>2 / 1</code>	งานพร้อมกันสูงสุด

ค่าตั้งใน render.yaml	ค่า	ความหมาย
PROVIDER_TRANSPORT_RETRIES	0	ไม่ลองเรียกผู้ให้บริการซ้ำ
SHUTDOWN_DRAIN_SECONDS	20	เวลารองานค้างก่อนปิด
16 ค่าแบบ sync: false	ตั้งใน Dashboard	DATABASE_URL, BUSINESS_DATA_KEY, PROVIDER_NETWORK_ENABLED, คีย์ของ LLM, guard และ vision, PROVIDER_BUDGET_CYCLE_ID, CLOUD_CALL_LIMIT, PROJECT_BUDGET_PRIOR_SPEND_THB, ค่าบัญชีทดลอง และ Google OAuth

MEDICAL_HARNESS_ENABLED และ flag ของเอกสารองค์กร (org_*) ไม่อยู่ใน Blueprint จึงปิดตามค่าเริ่มต้นใน config.py

4.2 วงจรชีวิตของ process

1. scripts/run_business.py สร้าง Uvicorn หนึ่ง worker ที่ 0.0.0.0:\$PORT และ timeout_graceful_shutdown = drain + 5 วินาที
2. lifespan ใน main.py สร้าง schema ของฐานข้อมูลใน thread (จำกัด 15 วินาที) แล้วตั้งสถานะ started
3. /health คือ liveness ส่งรุ่นและ commit ส่วน /ready คือ readiness: ต้อง started ไม่อยู่ระหว่าง drain และ SELECT 1 สำเร็จภายใน 1 วินาที (ผลที่สำเร็จเก็บ 2 วินาที) มิฉะนั้นตอบ 503
4. เมื่อได้ SIGTERM ครั้งแรก DrainingServer เริ่ม drain: /ready ตอบ 503 งานใหม่ได้ server_draining งานที่กำลังทำรอได้ 20 วินาทีแล้วถูกยกเลิก จากนั้น process จบด้วยสถานะ 0 สัญญาณครั้งที่สองหยุดทันที

5. โครงสร้างโค้ด

5.1 Routers

ไฟล์	Prefix	สิ่งที่ให้บริการ
<code>routers/business.py</code>	<code>/api/business</code>	session, บัญชี, แชต, ใบผล, การจอง, แผน, staff inbox, การชำระเงินและ webhook (56 endpoint)
<code>routers/business_ops.py</code>	<code>/api/business</code>	ค้นและเทียบแพ็คเกจ, การแจ้งเตือน, ปฏิทิน, ใบเสนอราคา PDF, dashboard, ลูกค้า, งบ, audit
<code>routers/chats.py</code>	<code>/api/business</code>	รายการแชตและโปรเจกต์ (สูงสุด 30 โปรเจกต์)
<code>routers/ai_admin.py</code>	<code>/api/business/staff/ai-providers</code>	ผู้จัดการตั้งผู้ให้บริการต่อ slot และทดสอบ 1 ครั้ง
<code>routers/harness_admin.py</code>	<code>/api/business/staff/harness</code>	อ่าน บันทึก และย้อนรุ่น Company Harness
<code>routers/knowledge_admin.py</code>	<code>/api/business/staff/knowledge</code>	รายการความรู้ พัก/เปิด และหน้า PDF
<code>routers/public.py</code>	<code>/api/business/site</code>	ข้อมูลหน้าเว็บสาธารณะ ไม่มีข้อมูลส่วนบุคคล
<code>routers/site.py</code>	ไม่มี	หน้า HTML: <code>/</code> , <code>/packages</code> , <code>/compare</code> , <code>/centers</code> , <code>/lab-reports</code> , <code>/sources</code> , <code>/hospital-links</code> และอื่น ๆ
<code>routers/google_auth.py</code>	<code>/api/business/auth/google</code>	Google sign-in (PKCE S256, state cookie) สำหรับลูกค้านั้น
<code>routers/organization_sources.py</code>	<code>/api/business/organization-documents</code>	เอกสารขององค์กร (ตอบ 404 เมื่อปิด flag)
<code>routers/samples.py</code>	<code>/api/samples</code>	ภาพใบผลส่งเคราะห์ 6 ใบ และการตรวจสิทธิ์เรียก AI

5.2 Services

กลุ่ม	ไฟล์
คำขอและความทนทาน	<code>execution.py</code> (request ID, deadline, admission, การยกเลิก, NDJSON, log), <code>request_limits.py</code>
Agent	<code>business_agent.py</code> (ไปป์ไลน์), <code>agent_tools.py</code> (typed tools), <code>runtime_skills.py</code> , <code>harness_config.py</code> , <code>business_dots.py</code> (บทบาท), <code>conversation_agent.py</code> (schema, ซ่อม JSON, ตรวจสอบคำตอบ), <code>answer_checks.py</code> , <code>model_harness.py</code>
ผู้ให้บริการและค่าใช้จ่าย	<code>conversation_transport.py</code> , <code>providers.py</code> , <code>cost_ledger.py</code> , <code>free_policy.py</code> , <code>model_registry.py</code>
ความปลอดภัย	<code>conversation_guard.py</code> , <code>trusted_origins.py</code> , <code>document_render.py</code> , <code>document_worker.py</code>
ความรู้	<code>evidence_search.py</code> , <code>knowledge_admin.py</code> , <code>hospital_links.py</code> , <code>organization_sources.py</code>
ไบโพล	<code>report_reader_v2.py</code> , <code>lab_fields_v2.py</code> , <code>business_plans.py</code>
ข้อมูลและธุรกิจ	<code>business_store.py</code> , <code>guest_memory.py</code> , <code>chat_sessions.py</code> , <code>business_ops.py</code> , <code>business_documents.py</code> , <code>business_integrations.py</code> , <code>business_worker.py</code> , <code>demo_accounts.py</code>

6. วงจรของคำขอ

6.1 ชั้นก่อนถึง route

ทุกคำขอผ่าน middleware `RequestBoundary` แบบ ASGI ล้วน ซึ่งทำ 4 อย่าง: สร้างเลขอ้างอิงคำขอใหม่ทุกครั้งและส่งกลับใน `x-request-id`, จำกัดขนาด body (10 MB สำหรับ `/reports/read` และ `/chat/report`, 4 MB สำหรับ POST/PUT/PATCH อื่นของ `/api/business`) ทั้งจาก Content-Length และระหว่างอ่าน, ใส่ security headers และเขียน log หนึ่งบรรทัดแบบ JSON ต่อคำขอ

route ของ AI ตรวจสอบเพิ่มอีก 3 ชั้น: origin ต้องตรงกับ host (หรืออยู่ใน `TRUSTED_ORIGINS`), session cookie (`HttpOnly`, `SameSite=Strict`) และ CSRF header `X-Business-CSRF` และ rate limit 120 คำขอต่อนาทีต่อ IP ในหน่วยความจำ

6.2 Execution context

`execution.start()` สร้าง context หนึ่งชุดต่อคำขอ AI ซึ่งถือ request ID, turn ID, deadline แบบ monotonic ของทั้งเส้นทาง, ช่องทำงาน (admission slot) และตัวยกเลิก

- **Admission** ถ้างาน AI เต็ม 2 งาน (หรือ OCR 1 งาน) คำขอใหม่ได้ `503 server_busy` พร้อม `Retry-After: 5` วินาที ไม่มีคิวและไม่เรียกผู้ให้บริการ
- **Deadline** แชนต์ 220 วินาที อ่านไบต์ 150 วินาที ครอบคลุมการอ่าน เขียนฐานข้อมูล ทุก agent การเขียนใหม่ และการซ่อม JSON ขึ้นใหม่จะไม่เริ่มถ้าเหลือเวลาน้อยกว่า 1 วินาที
- **การยกเลิก** ปุ่มหยุด การปิดการเชื่อมต่อ deadline และการปิดระบบยกเลิกการเรียกผู้ให้บริการที่ค้าง ฆ่า process อ่านไฟล์ และคืนช่องทำงาน
- **Storage นอก event loop** route ที่ใช้ฐานข้อมูลอย่างเดียวเป็นฟังก์ชันปกติที่ FastAPI รันใน thread ส่วนในไปป์ไลน์ใช้ `offload()` และ PostgreSQL ตั้ง `statement_timeout=15000` และ `lock_timeout=10000`

6.3 สัญญา NDJSON

เมื่อเบราว์เซอร์ส่ง `Accept: application/x-ndjson` คำตอบเป็นสตรีมบรรทัด JSON ที่มีลำดับแน่นอน

เหตุการณ์	เมื่อไร	ข้อมูล
<code>accepted</code>	บรรทัดแรกทันทีที่รับงาน	<code>request_id</code> , <code>deadline_ms</code> , <code>heartbeat_ms</code>
<code>step</code>	ทุกขั้นเริ่มและจบ	<code>id</code> , <code>state</code> (running, done, error), <code>label</code> , <code>detail</code> , <code>elapsed_ms</code> , <code>duration_ms</code>

เหตุการณ์	เมื่อไร	ข้อมูล
heartbeat	ทุก 10 วินาทีที่ไม่มีเหตุการณ์อื่น	elapsed_ms
done	สำเร็จ (บรรทัดสุดท้าย)	result, request_id, จำนวนเหตุการณ์ที่ถูกตัดถ้ามี
error	ล้มเหลว (บรรทัดสุดท้าย)	code, message, status, origin, request_id, step


ทุกสตรีมจบด้วย `done` หรือ `error` เพียงหนึ่งบรรทัด คิวภายในจำกัด 256 เหตุการณ์ ฟังก์ชัน `stream.js` มี watchdog 2 ตัว (เจียบเกิน 35 วินาที และ `deadline + 10` วินาที) แยกหน้า HTML ของ proxy, JSON error, สตรีมที่ขาดก่อนบรรทัดสุดท้าย และบรรทัดที่อ่านไม่ได้ ข้อความของลูกค้ากลับไปช่องพิมพ์เมื่อคำขอล้มเหลว

6.4 รหัสข้อผิดพลาด

ข้อผิดพลาดทุกตัวเป็น `ConversationError` ที่มี `code`, `status` และ `origin` (client, app หรือ upstream) ตัวอย่างกลุ่มหลัก

กลุ่ม	รหัส (HTTP)
ความทนทาน	<code>server_busy</code> 503, <code>server_draining</code> 503, <code>request_timeout</code> 504, <code>cancelled</code> 409/499, <code>storage_unavailable</code> 503
ผู้ให้บริการ	<code>upstream_timeout</code> 504, <code>upstream_unavailable</code> 502, <code>upstream_rate_limited</code> 503, <code>provider_rejected</code> 502, <code>provider_response_invalid</code> 502, <code>offline</code> 503
งบและนโยบาย	<code>budget_exhausted</code> 429, <code>cycle_required</code> 503, <code>free_policy_blocked</code> 409, <code>free_quota_exhausted</code> 429
การตรวจคำตอบ	<code>citation_invalid</code> , <code>observation_invalid</code> , <code>price_invalid</code> , <code>evidence_review_failed</code> , <code>evidence_missing</code> , <code>review_failed</code> , <code>role_violation</code> (502) และ <code>safety_blocked</code> 422
ใบผล	<code>file_too_large</code> 413, <code>unsupported_image</code> 415, <code>page_limit</code> 422, <code>document_timeout</code> 422, <code>not_a_report</code> 422

7. Agent flow ของหนึ่งข้อความ



ภาพที่ 2 การไหลของข้อมูลของหนึ่งข้อความ (กล่องสีม่วงเรียกโมเดล จุดสีม่วงแสดงใน Process Explainability)

7.1 Agent และ slot ของผู้ให้บริการ

ระบบมี 3 slot หลักและ agent ที่ตั้งผู้ให้บริการแยกได้ agent ที่ยังไม่ได้ตั้งใช้ค่าของ slot 11m ผู้จัดการตั้งค่าได้ที่หน้าผู้ให้บริการ AI คีย์ถูกเข้ารหัสและ

แสดงเพียง 4 ตัวท้าย

Agent / slot	หน้าที่	ผลลัพธ์	ค่าเริ่มต้น
guard	ตรวจสอบข้อความเข้า คำตอบ และข้อความจากเอกสาร	ป้ายความปลอดภัย	iApp openthai-systemone
agent_plan	Planner: action, บทบาท, คำค้น, รหัสแพ็คเกจ	JSON Plan (≤ 900 tokens)	Typhoon typhoon-v2.5-30b-a3b-instruct
agent_advisor	Health-check Advisor เขียนคำตอบเรื่องบริการ	JSON Answer	เหมือน llm
agent_explainer	Report Explainer อธิบายใบผลที่ยืนยันแล้ว	JSON Answer	เหมือน llm
agent_review	Reviewer ตรวจสอบหลักฐาน คำ และขอบเขต	JSON EvidenceReview (≤ 300 tokens)	เหมือน llm
vision	อ่านภาพใบผล หน้าละครึ่ง	ข้อความ	Typhoon typhoon-ocr
agent_medical_analyzer, agent_thai_composer	วิเคราะห์ใบผลแบบมีโครงสร้างแล้วเรียบเรียงไทย	JSON ที่ตรวจด้วย schema	ปิด (ต้องตั้งโมเดลและราคาที่ตรวจแล้ว)

ผู้ให้บริการที่เลือกได้มี 15 แบบ เช่น Typhoon, OpenAI, Anthropic, Gemini, OpenRouter, DeepSeek, Qwen และ Llama Guard (`services/providers.py`) ทุกคำขอใช้ snapshot ของการตั้งค่าชุดเดียวตลอดเส้นทาง

7.2 ลำดับขั้นของ `business_agent.run`

#	ขั้น (step id)	สิ่งที่เกิดขึ้น	เรียกโมเดล
1	harne ss	อ่าน snapshot ของ Company Harness (รุ่นและ SHA-256)	—
2	safet y_in	regex ภาษาไทยและอังกฤษ ถ้าพบคำสั่งแทรกหยุดทันที แล้วส่งข้อความให้ guard	guard
3	plan	planner เห็นข้อความ ประวัติ 12 รอบ และชื่อการตรวจ ในใบผล (ไม่เกิน 40 ชื่อ ไม่เห็นค่า)	planner
4	—	โค้ดตัดสินบทบาท: คำขออธิบายใบผลไปที่ Explainer, คำถามที่ระบุชื่อแพ็กเกจไปที่บทบาทที่อ่านแคตตาล็อก, action ที่บทบาททำไม่ได้ย้ายไปบทบาทที่ทำได้หรือกลายเป็นคำถามกลับ	—
5	tool_ *, data	lookup_packages, lookup_branches, lookup_policies พร้อมกันตามสิทธิ์ของบทบาท, compare_packages เมื่อมี 2-4 แพ็กเกจ, get_external_hospital_offer เมื่อข้อความเอ่ยชื่อโรงพยาบาล	—
6	searc h	retrieve_evidence ค้น BM25 เมื่อมีคำค้นและบทบาท อ่านความรู้ทางการแพทย์ได้	—
7	repor t	get_confirmed_report_rows เมื่อมีใบผลที่ยืนยันแล้วและ บทบาทอ่านใบผลได้	—
8	—	สร้างตัวอย่างการกระทำจากข้อมูลเซิร์ฟเวอร์ (preview_booking สำหรับจองหรือเสนอราคา) และป้อนัด ไม่เกิน 2 ปุ่ม	—
9	skill s	เลือก runtime skills ตามบทบาท งาน และหลักฐาน	—
10	analy ze	(เมื่อเปิด medical harness) วิเคราะห์ใบผลแล้วให้ Thai composer เป็นผู้เขียน	analyzer
11	draft	ผู้เขียนตามบทบาทเขียน JSON พร้อม [source-id] ความยาวตาม Harness (ค่าเริ่มต้น 2,400 tokens)	ผู้เขียน

#	ขั้น (step id)	สิ่งที่เกิดขึ้น	เรียกโมเดล
12	–	ตรวจโน้ต: citation ต้องอยู่ในหลักฐาน (การแพทย์ ≤ 8 , รวม ≤ 30), ไม่มีลิงก์/HTML/ภาพ, ค่าตรงแถวที่ยืนยัน, จำนวนเงินรู้จัก, ข้อความทางการแพทย์ต้องมีแหล่งการแพทย์, บทบาทที่ห้ามขายไม่ขาย และเติมคำแนะนำค่าวิกฤต	–
13	reviewer	reviewer ตรวจ supported, values_preserved, within_scope	reviewer
14	–	ถ้าขั้น 12–13 ไม่ผ่านในรอบแรก เขียนใหม่ได้ 1 ครั้ง แล้วตรวจทุกข้ออีกครั้ง (ไม่เขียนใหม่เมื่อ guard ปฏิเสธ)	ผู้เขียน, reviewer
15	safety_out	guard ตรวจคำตอบ คำถามต่อ ตัวอย่างการกระทำ และ เหตุผลของแผน	guard
16	offers	คำถามแพ็กเกจทั่วไป: แบนลิงก์โรงพยาบาลสถานะ VERIFIED ที่มีราคาไม่เกิน 3 รายการ หลังผ่านทุกการตรวจ	–

route `turn()` ครอบไปป์ไลน์นี้: ตั้งสถานะ busy ของบทสนทนา (เวลาที่เหลือ + 5 วินาที), ตัดคำตอบที่มาจากบทสนทนาเปลี่ยนรุ่นหรือ turn ID แล้ว, เก็บตัวอย่างการกระทำ 600 วินาที, บันทึกคำตอบพร้อมแหล่ง ขั้นตอน และผลการตรวจ หรือทำเครื่องหมายว่าลองใหม่ได้เมื่อรหัสอยู่ในกลุ่ม `retryable`

7.3 จำนวนการเรียกโมเดล

ข้อความปกติเรียก 5 ครั้ง (guard ขาเข้า, planner, ผู้เขียน, reviewer, guard ขาออก) กรณีมากที่สุด 12 ครั้ง เพราะการเรียกแบบ JSON แต่ละครั้งซ่อมรูปแบบได้ 1 ครั้ง และคำตอบเขียนใหม่ได้ 1 ครั้ง ถ้าเปิด medical analyzer เพิ่มอีก 1 ครั้ง ถ้า regex พบคำสั่งแทรก ระบบหยุดก่อนเรียกโมเดลใด ๆ

7.4 เส้นทางใบผลแล็บ

ใบผลใช้ 2 คำขอเพื่อให้ลูกค้ายืนยันค่าก่อนเสมอ

1. `POST /chat/report` รับ 1–3 ไฟล์หรือรายงานตัวอย่าง ตรวจสอบขนาดและ magic bytes ขอช่อง OCR แล้วส่งไฟล์ให้ process แยกแปลงเป็นภาพ (ขั้น `prepare`) จดสิทธิ์อ่านตามแผน (คืนสิทธิ์ถ้าล้มเหลว)
2. `report_reader_v2.read_report`: Typhoon OCR หน้าละครั้ง (≤ 3 หน้า) → guard ตรวจสอบข้อความในฐานะเอกสาร → โมเดลภาษาแปลงเป็นแถว → guard ตรวจสอบแถวอีกครั้ง → Python ปรับรูปแบบและคำนวณสถานะ จากช่วงที่พิมพ์ ระบบบันทึกเป็นร่างและแสดงการ์ดค่า ยังไม่อธิบาย
3. `POST /chat/report/confirm` รับค่าที่ลูกค้าแก้ (ถ้ามี) ตั้ง `confirmed` แล้ว เรียก `turn()` โดยบังคับบทบาท Report Explainer

การอ่านใบผลด้วย Typhoon เรียกโมเดลได้สูงสุด 7 ครั้ง (OCR 3, guard 1, แปลงแถว 2, guard 1)

8. Typed tools

เครื่องมือทั้งหมดอยู่ใน `services/agent_tools.py` schema รุ่น `labclear-tools-1.1.0` อินพุตเข้มงวด (ห้ามฟิลด์เกิน รหัสแพ็กเกจต้องตรง `^P\d{2}$`) บทบาทเรียกได้เฉพาะเครื่องมือที่ `scope` อยู่ในสิทธิ์อ่านของบทบาท

Tool	Scope	Advisor	Explainer	เวลา (วินาที)	รายการ สูงสุด	ขนาดสูงสุด (ตัวอักษร)
<code>lookup_packages</code>	catalog	✓	–	2	40	60,000
<code>compare_packages</code> (2–4 รหัส)	catalog	✓	–	2	1	20,000
<code>lookup_branches</code>	branches	✓	–	2	1	20,000
<code>lookup_policies</code>	policies	✓	✓	2	1	20,000
<code>retrieve_evidence</code> (คำค้น ≤ 700 , 1–8 รายการ)	medical	✓	✓	10	8	60,000
<code>get_confirmed_report_rows</code>	report	–	✓	2	1	80,000

Tool	Scope	Advisor	Explainer	เวลา (วินาที)	รายการ สูงสุด	ขนาดสูงสุด (ตัวอักษร)
<code>preview_booking</code> (ต้องมีสิทธิ์ quote/book)	catalog	✓	–	2	1	20,000
<code>get_external_hospital_offer</code> (เมื่อเปิด flag)	catalog	✓	–	2	20	20,000

ทุกการเรียกบันทึก audit: ชื่อ รุ่น scope บทบาท SHA-256 ของ อาร์กิวเมนต์ 16 ตัวแรก ผล จำนวนรายการ ขนาด การตัดทอน รหัสผิดพลาด และเวลา โดยไม่เก็บอาร์กิวเมนต์จริง audit นี้แสดงใน Process Explainability ผู้จัดการลดเวลาและจำนวนรายการได้แต่เพิ่มเกินค่าที่ลงทะเบียนไม่ได้ (`min(registered, harness)`) และปิดเครื่องมือได้ (`tool_disabled`)

9. Runtime skills และ Company Harness

9.1 Runtime skills

ชุดคำสั่ง `labclear-thai-health-communication` รุ่น 0.3.0-offline (`runtime_skills/thai_health/manifest.json`) มี 8 โมดูล ทุกไฟล์มี SHA-256 ใน manifest และถูกตรวจสอบทุกครั้งที่อ่าน ถ้าไม่ตรงได้ `skill_invalid` ลำดับโมดูลคงที่ และคำตอบบันทึกรุ่นของชุด รายชื่อโมดูล และ hash 16 ตัวแรก

โมดูล	รุ่น	เลือกเมื่อ
<code>core</code> (ล็อก)	0.2.0	ทุกข้อความ
<code>thai-style</code>	0.2.0	ทุกข้อความ (ทำตามเมื่อลูกค้าขอภาษาอื่น)
<code>evidence-citation</code> (ล็อก)	0.3.0	มีหลักฐานใดก็ตาม
<code>scope-uncertainty</code> (ล็อก)	0.3.0	มีหลักฐานการแพทย์ ใบผล หรือ action urgent/clarify
<code>lay-explanation</code>	0.3.0	มีหลักฐานการแพทย์และไม่มีใบผลที่ยืนยัน

โมดูล	รุ่น	เลือกเมื่อ
patient-explanation	0.2.0	มีใบผลที่ยืนยันแล้ว และบทบาทอ่านใบผลได้
package-advice	0.2.0	มีข้อมูลแพ็คเกจ และบทบาทเสนอราคาได้
package-compare	0.3.0	compare_packages สำเร็จ และบทบาทเสนอราคาได้

สถานะการตรวจของชุดคำสั่ง: clinical validation `NOT_RUN` และ language review `PENDING`

9.2 Company Harness

ผู้จัดการปรับการทำงานของ ผู้ช่วยได้โดยไม่แก้ไขโค้ด

(`services/harness_config.py`)

การตั้งค่า	ขอบเขต	ค่าเริ่มต้น
ใช้ runtime skills	เปิด/ปิด	ตาม <code>RUNTIME_SKILLS_ENABLED</code>
จำนวนแหล่งอ้างอิงต่อการค้น	1–8	6
ความยาวคำตอบสูงสุด	500–4,000 tokens	2,400
แต่ละ skill	เปิด/ปิด และถ้อยคำบริษัทไม่เกิน 4,000 ตัวอักษร	เปิด
แต่ละ tool	เปิด/ปิด เวลา 0.1–10 วินาที รายการ 1–40 (ไม่เกินค่าที่ลงทะเบียน)	2 วินาที, 8 รายการ

สิ่งที่เปลี่ยนไม่ได้: ปิดโมดูลที่ล็อก เพิ่มขีดจำกัดเกินค่าในโค้ด เพิ่ม skill หรือ tool ที่ไม่รู้จัก และสิทธิ์ของบทบาท ถ้อยคำของบริษัทต่อท้ายคำสั่งในฐานะ "ต่ำกว่านโยบายของแอป" ทุกการบันทึกตรวจสอบแบบ optimistic (`revision_conflict` 409) เก็บรุ่นก่อนหน้า บันทึก audit และย้อนกลับได้ (แสดง 20 รุ่นล่าสุด) SHA-256 ของการตั้งค่าบันทึกไว้ในทุกคำตอบ

10. ด้านผู้ให้บริการและค่าใช้จ่าย

ทุกการเรียกผู้ให้บริการผ่าน `post_json` ใน `services/conversation_transport.py` ตามลำดับนี้

1. endpoint ต้องเป็น HTTPS และ URL ที่กำหนดเองต้องไม่ใช่ IP ภายใน
2. นโยบายเรียกเฉพาะบริการฟรี (เมื่อกำหนด `FREE_ONLY_POLICY_PATH`):
host, path และโมเดลต้องตรงตัว สถานะ `VERIFIED_FREE_FOR_THIS_ACCOUNT` อายุไม่เกิน 7 วัน และโควตาต่อหน้าที่และต่อ run ที่ทุกบทบาทใช้ร่วมกัน
3. `PROVIDER_NETWORK_ENABLED` (ปิดเป็นค่าเริ่มต้น ได้ `offline` 503) และเพดานจำนวนครั้ง `CLOUD_CALL_LIMIT` ต่อรอบงบ `PROVIDER_BUDGET_CYCLE_ID` (นับแม้การเรียกล้มเหลว เกินได้ `budget_exhausted` 429)
4. จอค่าใช้จ่ายในบัญชีบาท `PROJECT_BUDGET_THB` (300 บาท) จากค่าประมาณ (ขนาดข้อความ + 256 + ภาพละ 1,500 tokens และ `max_tokens` ขาออก) ต้องระบุค่าใช้จ่ายก่อนหน้า `PROJECT_BUDGET_PRIOR_SPEND_THB`
5. ส่ง HTTP หนึ่งครั้ง ไม่ตาม redirect

เรื่อง	ค่า
เวลาต่อการเรียก	<code>min(timeout ของ slot, 75 วินาที, เวลาที่เหลือของคำขอ)</code> ค่า slot: LLM 60, vision 60, guard 20 วินาที
การลองใหม่	ไม่มี (<code>PROVIDER_TRANSPORT_RETRIES=0</code>) และไม่มีผู้ให้บริการสำรอง มีเพียงการซ่อม JSON 1 ครั้งและการเขียนคำตอบใหม่ 1 ครั้ง
ขนาดคำตอบ	ไม่เกิน 1,000,000 bytes และข้อความ 50,000 ตัวอักษร ปฏิเสธ <code>finish_reason</code> แบบ <code>length</code> หรือ <code>content_filter</code>
การปิดบัญชี	<code>succeeded</code> , <code>failed</code> หรือ <code>cancelled</code> การเรียกที่ล้มเหลวหรือถูกยกเลิกคิดเต็มค่าประมาณ และปิดบัญชีซ้ำไม่ได้
OpenRouter สำหรับ agent ใหม่	ต้องระบุ provider allowlist ส่ง <code>allow_fallbacks=false</code> , <code>data_collection=deny</code> และ zero data retention

11. คลังความรู้และ RAG

คลังความรู้ `knowledge/evidence/catalog.json` (schema `resultscope-evidence-v2`, รุ่น `2026-10-09-owner-approved-148`) มี 148 รายการจาก 29 ผู้เผยแพร่ (58 รายการเดิมและ 90 รายการที่เจ้าของอนุมัติ) แบ่งเป็น `public_reference` 80 รายการและ `public_education` 68 รายการ

เรื่อง	รายละเอียด
วิธีค้น	BM25 ($k_1=1.5$, $b=0.75$) บนชื่อเรื่อง aliases และเนื้อหา ไม่มี embedding หรือ vector database
การตัดคำ	คำละติน <code>[a-z0-9]+</code> และคู่อักษรไทย (bigram) คำถามภาษาไทยจึงเจอรายการภาษาอังกฤษผ่าน aliases ภาษาไทย
จำนวนผลลัพธ์	ค่าเริ่มต้น 6 ปรับใน Harness ได้ 1–8
ความถูกต้องตอนโหลด	รหัสไม่ซ้ำ, ชนิดข้อมูลสาธารณะเท่านั้น, SHA-256 ของเนื้อหาและไฟล์ต้นฉบับตรง, URL เป็น https ถ้าไม่ผ่านได้ <code>evidence_unavailable</code>
การจัดการ	ผู้จัดการเปิดอ่านเป็น PDF (ตรวจ hash ซ้ำ) และพักรายการได้ รายการที่พักไม่ถูกค้น

ลิงก์โรงพยาบาล (`business_data/hospital_links.json`) เก็บข้อเสนอจากหน้าเว็บทางการ 7 รายการ สถานะคำนวณทุกครั้ง (VERIFIED, UNVERIFIED, EXPIRED_SALE, STALE และอื่น ๆ) รายการที่ไม่ใช่ VERIFIED ถูกลบราคา host ต้องอยู่ใน allowlist 6 โดเมน และทุกรายการระบุว่าไม่ใช่พันธมิตร และจองผ่าน LabClear ไม่ได้

12. ข้อมูลและการจัดเก็บ

เรื่อง	รายละเอียด
ฐานข้อมูล	PostgreSQL (psycopg 3, connect_timeout 10) เมื่อมี DATABASE_URL มิฉะนั้น SQLite <code>data/business.sqlite3</code> (busy timeout 10 วินาที) บน cloud ต้องมี PostgreSQL

เรื่อง	รายละเอียด
ตาราง	<code>rs_entities(id, kind, owner, state, branch, payload, created)</code> เก็บทุก record และ <code>rs_mutex</code> สำหรับ lock ทั่วระบบ มี index (<code>kind, owner</code>)
ชนิดข้อมูล	บัญชีและ session, บทสนทนาและโปรเจกต์, นัด ใบผล ใบเสนอราคา การแจ้งเตือน audit, การชำระเงินจำลอง, LINE จ้างลอง, การตั้งค่า (AI, Harness, ความรู้), งบและโควตา
การเข้ารหัส	payload ทั้งก่อนเข้ารหัส Fernet ด้วย <code>BUSINESS_DATA_KEY</code> เหลือเพียง id, kind, owner, state, branch, created เป็นข้อความธรรมดา
รหัสผ่านและ session	PBKDF2-SHA256 310,000 รอบ เหลือ 16 bytes token ของ session เก็บเป็น SHA-256
ผู้เยี่ยมชม	อยู่ในหน่วยความจำของ process เท่านั้น อายุ 20 นาทีนับจากการใช้ครั้งล่าสุด สูงสุด 100 คนและ 64 MiB ลบเมื่อรีเฟรช ปิดหน้า หรือเข้าสู่ระบบ token อยู่ในหน่วยความจำของหน้าเว็บ

13. ความปลอดภัย

ด้าน	มาตรการ
Session	cookie <code>labclear_session</code> HttpOnly, SameSite=Strict, Secure บน cloud, อายุ 1 วัน; CSRF ตรวจสอบด้วย <code>hmac.compare_digest</code>
Origin	ปฏิเสธ <code>Sec-Fetch-Site: cross-site</code> ; Origin ต้องตรงกับ Host หรืออยู่ใน <code>TRUSTED_ORIGINS</code> แบบตรงตัว
อัตราการใช้	120 คำขอต่อนาทีต่อ IP; เข้าสู่ระบบ 8 ครั้งต่อ 15 นาที
ไฟล์อัปโหลด	1-3 ไฟล์ ไฟล์ละ ≤ 3 MB; PDF, PNG, JPEG ตาม magic bytes; ≤ 3 หน้า; ≤ 12 ล้านพิกเซล; เข้ารหัสภาพใหม่และลบ metadata
Process อ่านไฟล์	<code>python -I services/document_render.py</code> env เหลือเพียงค่าพื้นฐาน ไม่มี secret; <code>RLIMIT_AS</code> 384 MB, <code>RLIMIT_CPU</code> ตามเวลา, <code>RLIMIT_FSIZE</code> 0; เวลาไม่เกิน 30 วินาทีหรือเวลาที่เหลือ; ถูกฆ่าและเก็บกวาดเมื่อหมดเวลาหรือยกเลิก

ด้าน	มาตรการ
Guard	regex คำสั่งแทรก (ไทยและอังกฤษ) และ safety model ทั้งขาเข้าขาออก และเอกสาร; fail closed
คำตอบ	ตัด HTML ลิงก์ ภาพ และ URL ก่อนแสดง; เบราวเซอร์กรองด้วย DOMPurify
Headers	X-Request-ID, nosniff, Referrer-Policy: no-referrer, Permissions-Policy, X-Robots-Tag: noindex, CSP default-src 'self'; script-src 'self'; object-src 'none'; frame-ancestors 'none'
Webhook	ลายเซ็น HMAC พร้อมหน้าต่างเวลา 300 วินาที (Stripe sandbox และตัวจำลองการชำระเงิน)
Log	หนึ่งบรรทัด JSON ต่อคำขอด้วยรายการคีย์ที่อนุญาต ไม่มีข้อความลูกค้า ข้อมูลใบปล หรือคีย์

14. ความทนทาน

ค่าตั้งของความทนทานอยู่ใน `config.py` พร้อมขอบเขตที่ตรวจสอบตอนเริ่ม

ค่า	ค่าเริ่มต้น	ขอบเขต
CHAT_DEADLINE_SECONDS	220	30–600
REPORT_DEADLINE_SECONDS	150	30–600
STREAM_HEARTBEAT_SECONDS	10	2–30
AI_MAX_IN_FLIGHT	2	1–16
OCR_MAX_IN_FLIGHT	1	1–16 และไม่เกิน AI
PROVIDER_TRANSPORT_RETRIES	0	0 เท่านั้น
DOCUMENT_WORKER_SECONDS	30	2–120
DOCUMENT_WORKER_MEMORY_MB	384	192–4,096
SHUTDOWN_DRAIN_SECONDS	20	1–25

ชุดทดสอบ R01–R12 (`scripts/benchmark_resilience.py --offline`) จำลองผู้ให้บริการค้าง ตอบช้า ตอบ 502/503/429 หรือ JSON เสีย, หน้า HTML ของ proxy, สตรีมขาด, ปุ่มหยุดและการปิดหน้า, ผู้ใช้เกินขีดจำกัด, PDF

เสียหรือใหญ่เกิน, ฐานข้อมูลซ้ำ, SIGTERM, การทดลองใหม่ซ้ำ และ cold start ผลบน commit 3191f93: ผ่าน 12/12 (183 assertion) ไม่มีการเชื่อมต่อออก score hash 7ec88f1376d2d778 เท่ากันทั้งสอง seed ชุดใน เบราวเซอร์จริงผ่าน 10/10 คะแนนนี้คืออัตราผ่านของชุดทดสอบแบบ กำหนดได้ ไม่ใช่ uptime และไม่ใช่เวลาบน Render

เวลาของระบบเองในเครื่องทดสอบ (ไม่รวมเวลาโมเดล ไม่ใช่ Render):

/ready พร้อมใน 673 ms หลังเริ่ม process, แชนด์ p50 73 ms และ p95 91 ms, สองงานพร้อมกัน p50 173 ms, อ่านไบต์ผล p50 239 ms, หน่วย ความจำสูงสุด 81 MiB, ปิดหลัง SIGTERM 366 ms

15. การทดสอบและเครื่องมือ

ชุด	ที่อยู่	ผลบนรุ่นนี้
Unit และ API	tests/test_*.py (27 ไฟล์) ผ่าน scripts/offline_check.py ที่ปิดการเชื่อมต่อออก	371 ผ่าน
Browser UAT	tests/browser/uat.cjs	36/36
Browser upgrade	tests/browser/upgrade.cjs	10/10
ไทย/อังกฤษ	tests/browser/i18n_audit.mjs (390, 768, 1440 px)	43/43
ความทนทาน	tests/resilience/ และ tests/browser/resilience.cjs	12/12 และ 10/10
ชุดตามโจทย์	scripts/benchmark_labclear.py กับ eval/coursework/ (OFFLINE, REPLAY, LIVE_FREE)	OFFLINE 15/20 ทุก โปรไฟล์; LIVE_FREE ถูก รั้งที่ preflight
ชุดไฟล์ไบต์	eval/ocr_files/ 12 ไฟล์	OCR ตัวแทนอ่านตรง 217/252 ค่า

ชุด	ที่อยู่	ผลงานรุ่นนี้
Notebook	<code>notebooks/LabClear_Harness_Demo.ipynb</code>	แสดง prompt, tools, outputs และ rollout ของความทนทาน

สคริปต์สำคัญ: `run_business.py` (เริ่มบริการ), `dev_mock_api.py` (แอปจริงกับตัวแทนโมเดล), `boot_check.py` (ตรวจ entry point ของ Render), `score_benchmark.py` (ให้คะแนนแบบกำหนดได้), `measure_resilience.py` (วัดเวลาของระบบเอง), `build_diagrams.py`, `build_report.py` และ `build_docs_pdf.mjs` (เอกสาร)

16. ข้อจำกัดทางเทคนิคและงานต่อ

เรื่อง	รายละเอียด
ยังไม่ได้ทดสอบกับโมเดลจริงในรุ่นนี้	LIVE_FREE ถูกกระบังที่ preflight: นโยบายยังไม่ทบทวนสถานะฟรีของบัญชียังไม่ยืนยัน และไม่มี key ทดลอง
Render แพนฟรี	หลังหลังไม่มีการใช้งาน การตื่นอาจทำให้ proxy ตอบ 502 ก่อนแอปพร้อม
<code>/ready</code> ขึ้นกับ PostgreSQL	deploy ใหม่จะรับงานเมื่อฐานข้อมูลตอบเท่านั้น
Storage ยังอยู่บน event loop บางจุด	route คืนเงินของเจ้าหน้าที่ worker ของ LINE (ปิดบน Render) และตัวจำลอง LINE
Windows	ขีดจำกัดหน่วยความจำของ process อ่านไฟล์ใช้ได้ เฉพาะ POSIX
ค่าเริ่มต้นไม่ตรงกัน	CLOUD_CALL_LIMIT เป็น 200 ใน <code>config.py</code> แต่ 500 ใน <code>.env.example</code>
Rate limit	route ของ AI ใช้ token ของ rate limit 2 ครั้งต่อคำขอ
โค้ดเดิมที่ไม่อยู่ในเส้นทางจริง	<code>conversation_agent.run()</code> , <code>runtime_skills.bundle()</code> และ <code>image_validation.py</code>
งานระดับ P1	circuit breaker, นโยบายลองใหม่ และงานแบบ durable ยังไม่ได้ทำ

ภาคผนวก ก. เอกสารอ้างอิงใน repository

เรื่อง	ไฟล์
API ทั้งหมด	docs/api.md
สถาปัตยกรรม (ภาษาอังกฤษ)	docs/architecture.md
ผู้ให้บริการ AI	docs/ai-providers.md
ความทนทานและ runbook	docs/operations/resilience.md
Deploy และ Render CLI	docs/deploy/render.md
การทดสอบ	docs/testing.md
หลักฐาน	docs/evidence/current/ , docs/evidence/history/