

LabClear 4.0.0-rc2 (ร่นรวม) รายงานทางเทคนิค

วิชา 06048308 Intelligent Chatbot Development · Final Project

ผู้พัฒนา นายวัชรินทร์ บัวสอน (68076055) · นายศิริพล ศรีเฮงไพบูลย์ (68076060)

รุ่น 4.0.0-rc2 · ฐาน Codex `main` `c970410` · branch `integration/labclear-4.0-rc1` · commit ที่ทดสอบ `6f41a78` (ชุดเว็บรันซ้ำบน `a4aec07`) · วันที่ 9 ตุลาคม 2569

รายงานนี้เดิมเขียนให้ Claude branch 4.0.0 (`release/4.0.0`, commit `95bf3d7`) ซึ่งเลือก Cloudflare Workers Paid และชุดโมเดล OpenRouter แบบเร็ว ฉบับนี้ปรับให้ตรงกับ ร่นรวม ที่ใช้ backend ของ Codex กับหน้าเว็บของ Claude ข้อเท็จจริงทั้งหมดอ้างอิง `release-4.0.0.md`, หลักฐานของร่นรวม rc2, ผลชุดทดสอบตามโจทย์ และโค้ดใน repository rc2 เพิ่ม free-first harness (หัวข้อ 6) บน rc1 ผลของ rc1 (`c8f3547`) เป็นประวัติ ไม่ใช่ผลของร่นนี้ ร่นรวมเป็น candidate สำหรับตรวจรับ ยังไม่ได้ merge ยังไม่ได้ deploy ยังไม่ได้เรียกผู้ให้บริการ AI จริง (LIVE_FREE ถูก preflight หยุดไว้ เพราะไม่มี key และยังไม่มีผู้ยืนยันว่าบัญชีใช้ฟรี) และไม่ได้แก้ ENV ของระบบจริง ความสามารถใหม่ของ Codex ทั้ง 6 flag และนโยบาย free-only ปิดเป็นค่าเริ่มต้น

1. สรุป

LabClear เป็นแชทบอตของคลินิกตรวจสุขภาพจำลอง ลูกคำถามเรื่องแพ็กเกจ ราคา และการนัดหมายได้ ส่งภาพใบผลแล็บให้ AI อ่าน ยืนยันค่า แล้วได้คำอธิบายภาษาไทยพร้อมแหล่งอ้างอิง ส่วนเจ้าหน้าที่ใช้หน้า `/staff` ยืนยันนัดตอบลูกค้า ออกใบเสนอราคา กำหนดสมาชิกองค์กร และคุมงบ AI

ร่นรวมตอบความเห็นของ CEO 5 ข้อหลังการนำเสนอความก้าวหน้า โดยประกอบงานสองชุดที่ทำแยกกัน

ส่วน	มาจาก	ในร่นรวม
Backend FastAPI, ความปลอดภัย, การไม่เก็บแชตผู้เยี่ยมชม, model harness, เอกสารองค์กร, ลิงก์โรงพยาบาล, สัญญา API	Codex <code>main</code>	คงไว้ทั้งหมด
ส่วนต่อขยาย backend	ร่นรวม (ดัดแปลงจาก Claude)	<code>routers/public.py</code> แบบอ่านอย่างเดียว, <code>TRUSTED_ORIGINS</code> (ว่างเป็นค่าเริ่มต้น), <code>/site/membership</code> , <code>VERSION = 4.0.0-rc2</code>
Free-first harness (rc2)	ร่นรวม	typed tools 8 ตัว, runtime skills เลือกตามงาน 0.3.0, ภาพสังเคราะห์ผ่านการอัปโหลดใน <code>APP_ENV=test</code> , นโยบาย free-only + โควตากกลาง, ชุดทดสอบตามโจทย์ OFFLINE / REPLAY / LIVE_FREE

ส่วน	มาจาก	ในรุ่นรวม
หน้าเว็บ Next.js 16 + React 19 + React Three Fiber ภาษาไทยเป็นค่าเริ่มต้น	Claude 4.0.0	นำมาใช้ ปรับเฉพาะจุดที่สัญญา API ต่างกัน
Deploy	Codex (Render เดิม)	<code>render.yaml</code> ไม่เปลี่ยน เว็บเป็นบริการ Render ตัวที่สอง แบบเลือกได้
Cloudflare Workers Paid + Containers	Claude 4.0.0	เลื่อนไว้ เก็บไฟล์ครบ ไม่ใช้
ฐานความรู้	Codex 58 รายการที่ตรวจ แล้ว	ระเบียบที่ Claude เขียนเพิ่ม 90 รายการอยู่ในคิวรอตรวจ ไม่ ถูกค้น

ข้อ	ความเห็น CEO	ผลในรุ่นรวม
1	แหล่งอ้างอิงน้อยและเจาะจงบางโรงพยาบาล อยากให้ลูกค้าองค์กรอัปโหลดเอกสารของโรงพยาบาลเองได้	ฐานที่ค้นคง 58 รายการ แหล่งใหม่เข้าคิวรอตรวจ เอกสารองค์กรใช้ระบบของ Codex (สมาชิก ร่าง อนุมัติ รุ่น ถอน) และเพิ่มหน้าลิงก์โรงพยาบาล
2	ถ้าไม่ได้เข้าสู่ระบบ ประวัติแชตหายเมื่อรีเฟรช	คงการล้างเมื่อรีเฟรช และใช้กฎของ Codex ที่ลบแชตผู้เยี่ยมชมเมื่อเข้าสู่ ระบบ พร้อมกันคำตอบเก่าแสดงทับบัญชีใหม่
3	ย้ายจาก Render ไป Cloudflare บนโดเมนที่ทีมซื้อไว้	เจ้าของเปลี่ยนเป้าหมายกลับเป็น Render เดิม Cloudflare Workers Paid เลื่อนไว้ แผนฟรีใช้เป็น DNS/proxy ได้ภายหลัง
4	ใช้ OpenRouter key ของทีม เลือกโมเดลถูก ดี เร็ว งบ USD 10 และพิจารณา embedding	model harness ของ Codex: เลือกผู้ให้บริการต่อ slot และ agent บทบาทใหม่ปิดเป็นค่าเริ่มต้น เพดาน 300 บาท รอบ rc2 ใช้ Typhoon text/OCR + OpenThai-SystemOne เป็น baseline แบบ free-first ส่วน OpenRouter และ embedding พักไว้ (ไค้ดยังอยู่)
5	หน้าเว็บเน้นภาษาไทย ใช้ Next/React/Three ได้ ให้เด่นและเข้าใจง่าย	ใช้เว็บ Next.js ของ Claude ทั้งหมด ภาษาไทยเป็นค่าเริ่มต้น สลับ EN ได้

หลักฐานของ rc2 (commit `6f41a78`, ข้อมูลจำลองและตัวแทนโมเดล): pytest ผ่าน 328, browser เดิมของ Codex ผ่าน 36/36, ชุด upgrade ของ Codex ผ่าน 10/10, offline fixture 60/60, Render endpoint smoke ผ่าน, web UAT ของ Next.js ผ่าน 53/53 บน `a4aec07` (สองรอบก่อนหน้าบน `6f41a78` ได้ 52/53 ดูหัวข้อ 8) และชุดที่ปิด flag ทั้งหมดผ่าน 5/5 ชุดทดสอบตามโจทย์ 20 กรณีรันครบในโหมด OFFLINE ผ่านเกณฑ์อัตโนมัติระดับ pipeline 15/20 และ REPLAY ตรงกัน แต่เป็นผลของตัวแทนผู้ให้บริการ ไม่ใช่คำตอบของโมเดล คุณภาพคำตอบกับโมเดลจริง (LIVE_FREE) ยังไม่ได้วัด


2. ธุรกิจและขอบเขต

LabClear จำลองคลินิกตรวจสุขภาพขนาดเล็กที่มี 3 ศูนย์ (กรุงเทพฯ อารีย์ เชียงใหม่ สุเทพ ขอนแก่น) เปิดจันทร์-เสาร์ 07:00-16:00 น. ขายสองอย่าง

- แพ็กเกจตรวจสุขภาพ 18 รายการ แพ็กเกจหลัก 4 รายการจองได้ทันที (เริ่ม ฿1,190) การตรวจติดตาม 11 รายการต้องให้ทีมงานพิจารณาก่อน และแพ็กเกจจองคอร์ 3 รายการสำหรับ 20 คนขึ้นไป
- AI Lab Report แผนฟรีอ่านผลได้ 1 รายงาน แผน Plus ฿355 ต่อ 30 วัน อ่านใบผลหลายหน้าและดูผลย้อนหลัง


ข้อมูลธุรกิจ ราคา การชำระเงิน และใบผลแล็บทั้งหมดเป็นข้อมูลสมมติ เซตบอตต้องตอบจากแค่तालिका นโยบาย และฐานความรู้ที่ตรวจแล้วเท่านั้น ห้ามวินิจฉัย ห้ามสั่งยาหรือบอกขนาดยา ห้ามแต่งราคาหรือส่วนลด และห้ามเปิดเผยข้อมูลลูกค้าคนอื่น การจอง การชำระ และการคืนเงินเกิดขึ้นหลังลูกค้ากดยืนยันและเจ้าหน้าที่ตรวจเท่านั้น รายละเอียดอยู่ใน [business.md](#) และ [chatbot-spec.md](#)

3. การออกแบบระบบ



3.1 องค์ประกอบ

ชั้น	องค์ประกอบ	หน้าที่
Web (เลือกได้)	บริการ Render <code>labclear-web</code> : Node 22, Next.js 16	หน้าสาธารณะเป็น server component ส่วน <code>/app</code> และ <code>/staff</code> เป็น client component; <code>next.config.ts</code> rewrite <code>/api/*</code> และ <code>/health</code> ไปที่ <code>API_ORIGIN</code>
API	บริการ Render <code>labclear</code> : Python 3.12, FastAPI (Codex, <code>render.yaml</code> เดิม)	session, CSRF, origin, rate limit, ทุกการทำงานทางธุรกิจ และหน้า Jinja เดิม รัน 1 instance
Core	<code>business_agent</code> , <code>conversation_guard</code> , <code>report_reader_v2</code> , <code>conversation_transport</code> , <code>cost_ledger</code>	pipeline ของแชต การตรวจสอบความปลอดภัย การอ่านใบผล และด่านก่อนเรียกโมเดล
Core	<code>agent_tools</code> (rc2)	เครื่องมือข้อมูลแบบ typed 8 ตัวที่ pipeline ใช้ดึง catalog สาขา นโยบาย หลักฐาน แฉใบผลที่ยืนยัน และตัวอย่างใบเสนอราคา ตามสิทธิ์อ่านของบทบาท
Core (opt-in)	<code>model_harness</code> , <code>runtime_skills</code> , <code>organization_sources</code> , <code>free_policy</code> (rc2)	Medical analyzer และ Thai composer, คำสั่งภาษาไทยที่ตรวจ hash แล้วและเลือกตามงาน, เอกสารองค์กร, นโยบาย free-only (ทำงานเมื่อเปิด flag หรือตั้งไฟล์นโยบาย)
Data	<code>knowledge/evidence/catalog.json</code>	ฐานความรู้ 58 รายการ ค้นด้วย BM25
Data	<code>knowledge/acquisition/</code>	คิวแหล่งรอตตรวจ (Codex 15 + 6, Claude 90) ไม่ถูกค้น
Data	Render PostgreSQL (SQLite ในเครื่อง)	ตาราง <code>rs_entities</code> ทุกแถวเข้ารหัส Fernet ด้วย <code>BUSINESS_DATA_KEY</code>
External	ผู้ให้บริการ AI ตาม slot	ค่าเริ่มต้น Typhoon (โมเดลภาษา), iApp OpenThai-SystemOne (safety), Typhoon OCR; ผู้จัดการเปลี่ยนเป็น OpenRouter หรือรายอื่นได้



3.2 หน้าเว็บกับ API uu Render

เบราว์เซอร์คุยกับบริการเว็บเพียง origin เดียว cookie `labclear_session` (HttpOnly, SameSite=Strict) จึงเป็นของโดเมนเว็บ บริการเว็บส่งต่อ `/api/*` ไปยังบริการ API ด้วย HTTPS คำขอที่ไปถึง API มี `Host` ของ API แต่ `Origin` ของเว็บ กฎเดิมของ Codex ที่ให้ `Origin` ตรงกับ `Host` จึงปฏิเสธคำขอนี้ รันรวมเพิ่ม `services/trusted_origins.py` และค่า `TRUSTED_ORIGINS` ที่เทียบ origin แบบตรงตัวทั้ง scheme, host และ port ไม่รับ wildcard, path หรือ credential ค่าเริ่มต้นว่าง API จึงทำงานแบบเดิมจนกว่าเจ้าของจะใส่ origin ของเว็บ การตรวจ `Sec-Fetch-Site: cross-site` ยังปฏิเสธเสมอ


ทางเลือกที่พิจารณา: ส่งออกหน้าเว็บเป็นไฟล์ static ให้ FastAPI เซิร์ฟ (origin เดียวโดยไม่ต้อง proxy) ต้องเปลี่ยนหน้าแบบ dynamic หลายหน้า เช่น `/lab-report/[id]` จึงไม่ทำในรอบนี้ ส่วน CORS แบบมี credential ต้องเปลี่ยน cookie เป็น SameSite=None ซึ่งเพิ่มช่องโจมตีข้ามไซต์

3.3 ข้อมูล

ข้อมูลการทุกชนิดอยู่ในตารางเดียว `rs_entities(id, kind, owner, state, branch, payload, created)` โดย `payload` เป็น JSON ที่เข้ารหัส Fernet เอกสารองค์กรของ Codex เป็นแถวชนิด `organization_source` ที่มีสถานะ `draft`, `approved`, `rejected`, `revoked` หรือ `deleted` และสมาชิกองค์กรเก็บเป็นฟิลด์ `organization_id` กับ `organization_role` ในแถวผู้ใช้ รันรวมไม่เพิ่มตารางหรือ schema

ข้อมูลของผู้เยี่ยมชม (ข้อความ ภาพ ผลอ่านใบผล) ไม่ลงฐานข้อมูล อยู่ใน RAM ของ process Python เดียว
บริการ API จึงต้องมี instance เดียว

4. ข้อความหนึ่งข้อความเดินทางอย่างไร



1. เบราวเซอร์ POST /api/business/chat พร้อม Accept: application/x-ndjson ไปที่บริการเว็บ ซึ่ง rewrite ไปยัง FastAPI

2. ตรวจสอบ session, CSRF, origin (Host หรือ `TRUSTED_ORIGINS`) และ rate limit แล้วบันทึกข้อความ (บัญชี PostgreSQL ผู้เยี่ยมชมลง RAM)
3. ถ้าเปิดเอกสารองค์กร ตรวจสอบซ้ำว่าแหล่งส่วนตัวที่เคยใช้ในประวัติยังอนุมัติและเป็นขององค์กรเดิม ถ้าไม่ใช่ข้อความนั้นถูกตัดออกจาก context
4. ตรวจสอบรูปแบบการโจมตีด้วย regex ภาษาไทยและอังกฤษ ถ้าพบจะหยุดโดยไม่เรียกโมเดล แล้วตรวจสอบความเข้าด้วย safety model
5. Planner เลือก action บทบาท และคำค้น
6. ดึงข้อมูลผ่าน typed tools ตามสิทธิ์อ่านของบทบาท (catalog สาขา นโยบาย ค้น BM25 บนฐาน 58 รายการ แถวใบผลที่ลูกค้ายืนยันแล้ว) แต่ละเครื่องมือตรวจสอบ input แบบ strict มีเวลาและขนาดผลจำกัด และบันทึก audit ที่ส่งกลับใน `checks.tools` ข้อความที่อนุมัติแล้วขององค์กรใช้เฉพาะเมื่อเปิด `ORG_REFERENCE_INFERENCE_ENABLED` และผู้ให้บริการทุกตัวที่รับข้อมูลตั้งค่าแล้วและไม่ใช้โมเดล `:free`
7. ผู้เขียนคำตอบตามบทบาทเขียน JSON พร้อมรหัสแหล่งอ้างอิง (เมื่อเปิด `RUNTIME_SKILLS_ENABLED` ระบบเลือกโมเดลคำสั่งจาก `runtime_skills` ตามบทบาท action การมีใบผล ชนิดหลักฐาน และเครื่องมือที่ใช้จริง แล้วรายงานใน `checks.skills` และใช้ Medical analyzer + Thai composer กับใบผลจำลองในระบบ เมื่อเปิด `MEDICAL_HARNESS_ENABLED`)
8. Python ตรวจสอบ citation ค่าผลตรวจ จำนวนเงินเทียบเค็ดตาล็อก และขอบเขตของบทบาท แก้ได้หนึ่งรอบ แล้ว reviewer ตรวจสอบ และตรวจสอบความปลอดภัยออก
9. บันทึกคำตอบ แหล่งอ้างอิง (เอกสารองค์กรมีรุ่น ตำแหน่ง และ SHA-256) และขั้นตอน แล้วส่งผลลัพธ์เป็นบรรทัดสุดท้ายของ stream

ไปป์ไลน์ของ Codex เรียกโมเดลทีละครั้งตามลำดับ ข้อความปกติใช้ 5 ครั้ง และไม่เกิน 8 ครั้งเมื่อมีการแก้ไข ทุกการเรียกต้องผ่าน `PROVIDER_NETWORK_ENABLED` นโยบาย free-only เมื่อตั้งไว้ (host, path และโมเดลต้องตรง รายการที่ตรวจแล้ว และโควตาต่อนาที/ต่อ run ยังเหลือ) เพดานจำนวนครั้ง (`CLOUD_CALL_LIMIT` ค่าเริ่มต้น 200 ต่อ `PROVIDER_BUDGET_CYCLE_ID`) และบัญชีค่าใช้จ่ายบาท (`PROJECT_BUDGET_THB` 300 บาท) ก่อนเสมอ ขึ้นได้ล้มเหลว ระบบหยุดและแสดงสาเหตุพร้อมปุ่มลองใหม่ (fail closed) ลูกค้าเห็นแต่ละขั้นแบบ stream และดูย้อนหลังได้คำตอบ

การอ่านใบผลในแชตใช้ Typhoon OCR หน้าละหนึ่งครั้ง (เมื่อเปิด `VISION_ENABLED`) safety check ตรวจสอบข้อความที่อ่านได้ในฐานะเอกสาร โมเดลภาษาแปลงเป็นแถว แล้วตรวจแถวอีกครั้ง Python คำนวณว่าค่าอยู่ใน สูงกว่า หรือต่ำกว่าช่วงที่พิมพ์บนใบผล แล้วรอให้ลูกค้ายืนยันก่อนอธิบาย

5. การตัดสินใจตามความเห็น CEO

5.1 แหล่งอ้างอิงและเอกสารขององค์กร (ข้อ 1)

ฐานความรู้ Claude branch เคยขยายเป็น 135 รายการจาก 24 ผู้เผยแพร่ แต่ 77 รายการที่เพิ่มเขียนจากความรู้โดยไม่ได้เปิดหน้าเว็บต้นทาง (`verification.url_checked=false`) และมีร่างอีก 13 รายการของโรงพยาบาลที่ไม่มีลิงก์บทความเฉพาะ รวบรวมฐานที่ค้นไว้ที่ 58 รายการที่ตรวจแล้วของ Codex และย้ายทั้ง 90 รายการไปที่ `knowledge/acquisition/claude_candidates_400.json` สถานะ NOT_APPROVED (หน่วยงานรัฐไทย 5 สมาคมวิชาชีพไทย 13 โรงพยาบาลไทย 13 หน่วยงานสากล 27 แหล่งอ้างอิงสากล 32 รวม 26 ผู้เผยแพร่) การทดสอบใน `tests/test_integration_400.py` ยืนยันว่ารายการเหล่านี้ไม่ปะปนกับฐานที่ใช้งาน `python scripts/verify_sources.py --candidates` ช่วยตรวจได้เพียงว่าลิงก์ยังเปิดได้

trade-off ผู้ใช้ยังได้แหล่งอ้างอิงจาก 4 ผู้เผยแพร่เท่าเดิมจนกว่าจะตรวจแหล่งใหม่ แต่ไม่มีความเสี่ยงที่ระบบจะอ้างอิงข้อมูลที่ไม่มีใครเทียบกับต้นฉบับ

เอกสารขององค์กร รวบรวมใช้ระบบของ Codex แทนระบบรหัสเข้าร่วมของ Claude branch

ขั้น	ผู้ทำ	รายละเอียด
กำหนดสมาชิก	ผู้จัดการ LabClear	<code>/staff</code> → Organization membership: บัญชีที่ลงทะเบียนแล้ว + รหัสองค์กร <code>org_...</code> + บทบาท reader หรือ editor (<code>PUT /organization-documents/membership</code>)
อัปโหลด	ผู้แก้ไขขององค์กร	<code>/app</code> → My organization: TXT หรือ Markdown แบบ UTF-8 ไม่เกิน 256 KiB เก็บแบบเข้ารหัสเป็นร่าง ปฏิเสธไฟล์ซ้ำและไฟล์ที่ไม่ใช่ข้อความ องค์กรละไม่เกิน 100 ฉบับ
ตรวจ	ผู้แก้ไขขององค์กร	ดูตัวอย่าง แล้วอนุมัติหรือไม่อนุมัติ รุ่นใหม่ (<code>previous_id</code>) แทนรุ่นเดิมเมื่ออนุมัติ ถ้ารุ่นที่อนุมัติเปลี่ยนไประหว่างนั้นระบบปฏิเสธ
ค้นและดาวน์โหลด	สมาชิก	ข้อความต้นฉบับพร้อมรุ่นและบรรทัด ป้าย "ไม่ใช่คำตอบจาก AI" ดาวน์โหลดได้เฉพาะสมาชิกองค์กรเดียวกัน
ถอนหรือลบ	ผู้แก้ไขขององค์กร	คำตอบครั้งต่อไปใช้ไม่ได้ทันที การลบลบเนื้อหาออก
ใช้กับผู้ช่วย	เจ้าของระบบ	เปิด <code>ORG_REFERENCE_INFERENCE_ENABLED</code> หลังทบทวนนโยบายข้อมูลของผู้ให้บริการ (ปิดเป็นค่าเริ่มต้น)

หน้า My organization ของเว็บ Next.js ถูกเขียนใหม่ตามสัญญาณบนโครงหน้า การ์ด และ class เดิมของ Claude และถาม `GET /site/membership` ก่อน ผู้ที่ไม่ใช่สมาชิกจึงไม่เจอคำตอบ 403 หน้า staff "Organizations" และ "Reference document review" ของ Claude ไม่ได้นำมา เพราะใน Codex ผู้แก้ไขขององค์กรเป็นผู้ตรวจเอกสาร

ลิงก์โรงพยาบาล รวมนำข้อมูลของ Codex มาแสดงที่ `/hospital-links` ของเว็บ Next.js (`HOSPITAL_LINKS_ENABLED`) ราคาแสดงเฉพาะข้อเสนอที่ตรวจแล้วและยังไม่หมดอายุ ลิงก์ไม่ส่ง referrer และ

ไม่อ้างว่าเป็นพันธมิตรหรือจองได้

5.2 ประวัติแชตของผู้เยี่ยมชม (ข้อ 2)

ความเห็นนี้มีสองทางแก้ที่ขัดกัน: เก็บแชตไว้ในเบราว์เซอร์ให้ยังอยู่หลังรีเฟรช หรือคงการล้างไว้เพื่อความเป็นส่วนตัว คำถามเรื่องผลตรวจเป็นข้อมูลสุขภาพ เจ้าของโครงการจึงเลือก **ล้างทุกครั้งทีรีเฟรช** Claude branch เคยเพิ่มตัวเลือก "เก็บแชตนี้ไว้ในบัญชี" ตอนเข้าสู่ระบบ แต่ Codex กำหนดให้การเข้าสู่ระบบหรือสมัครบัญชีลบแชตผู้เยี่ยมชมและภาพ (ฟิลต์ `keep_guest_chat` ถูกปฏิเสธโดย schema แบบ strict) รุ้รวมจึงใช้กฎของ Codex

กลไก	ที่อยู่โค้ด
token ของผู้เยี่ยมชมอยู่ในหน่วยความจำของหน้าเท่านั้น ไม่ใช่ localStorage, sessionStorage, IndexedDB หรือ cookie	<code>web/lib/api/client.ts</code>
เมื่อปิดหรือรีเฟรช เบราร์เซอร์ส่ง beacon ไป <code>/api/business/guest/close</code> ให้เซิร์ฟเวอร์ลบข้อมูลใน RAM ทันที	<code>client.ts</code> , <code>routers/business.py</code>
หน้าที่กลับมาจาก back/forward cache ถูกโหลดใหม่	<code>client.ts</code> (pageshow)
แถบ "โหมดยุติเยี่ยมชม" และหน้าต่างเข้าสู่ระบบแจ้งว่าแชตชั่วคราวจะถูกลบ	<code>web/components/chat/guest.tsx</code> , <code>web/components/SignInDialog.tsx</code>
เข้าสู่ระบบส่งเฉพาะ email และรหัสผ่าน หน้าเว็บล้างข้อความออกทันที	<code>client.ts</code> , <code>Workspace.tsx</code> , <code>DockPanel.tsx</code> , <code>engine.ts</code>
คำตอบ <code>/workspace</code> ที่ขอในนามตัวตนเดิมถูกทิ้ง (<code>api.identity</code>)	<code>Workspace.tsx</code> , <code>DockPanel.tsx</code>
ผู้เยี่ยมชมที่ไม่ใช้งาน 20 นาที หรือ process restart ข้อมูลหาย	<code>services/guest_memory.py</code>

หลักฐาน: UAT R4-02, R4-03 (เข้าสู่ระบบแล้วข้อความหายทันที หลังรีเฟรช และในบัญชี), R4-04 (หน่วงคำตอบ `/workspace` ของผู้เยี่ยมชม 3.5 วินาทีระหว่างสมัครบัญชีแล้วยืนยันว่าไม่แสดงทับ) และ UI-33 ทั้งในเว็บ Next.js และชุดเดิมของ Codex

5.3 Deploy: กลับมาใช้ Render (ข้อ 3)

ทางเลือก	ข้อดี	ข้อเสีย / สถานะ
บริการ API เดิม + บริการเว็บ Next.js ตัวที่สองบน Render (รุ่นรวม)	ไม่เปลี่ยน <code>render.yaml</code> และบริการที่ใช้งานอยู่ ไม่มีค่าแผน Workers Paid ถอยกลับได้ง่าย	สองบริการต้อง build และหลักแยกกัน rate limit ผ่านเว็บใช้ bucket เดียว ต้องตั้ง <code>TRUSTED_ORIGINS</code>
หน้า Jinja เดิมของ Codex บนบริการ API เท่านั้น	ไม่มีบริการเพิ่ม	ไม่ได้หน้าเว็บ Next.js ที่ CEO ขอ ยังใช้ได้เป็นทางสำรอง

ทางเลือก	ข้อดี	ข้อเสีย / สถานะ
Cloudflare Worker 2 ตัว + Container + PostgreSQL ภายนอก (Claude branch)	origin เดียวผ่าน service binding	ต้องใช้ Workers Paid และ Docker เจ้าของเลือกเลื่อนไว้

ขั้นตอนอยู่ใน `deploy/render-web.md`: Root Directory `web`, build `npm ci && npm run build`, start `npm run start:render`, ENV `NODE_VERSION=22`, `API_ORIGIN=https://<API>` และเจ้าของตั้ง `TRUSTED_ORIGINS=https://<เว็บ>` ที่ API ตัวอย่าง blueprint อยู่ที่ `deploy/render/web-service.example.yaml` (ไม่ถูกอ่านอัตโนมัติ) หน้าเว็บสาธารณะรอ API ไม่เกิน 2.5 วินาที ถ้า API ยังไม่ตื่นจะใช้ข้อมูล seed ที่ bundle ไว้

งาน Cloudflare (`deploy/cloudflare/`, `Dockerfile`, `scripts/container_start.py`, `web/worker.ts`, `web/wrangler.jsonc`, สคริปต์ deploy) เก็บไว้เป็นทางเลือก workflow ของ GitHub Actions ย้ายไป `deploy/cloudflare/ci/` เพื่อไม่ให้ deploy เองเมื่อ push และ Docker image เพิ่ม `runtime_skills/` ที่ transport ของ Codex อ่านทุกครั้งที่เรียกโมเดล ค่า `vars` ใน wrangler อ้างการตั้งค่าของ Claude branch ที่ backend ของ Codex ไม่มี ต้องทำใหม่ก่อนใช้ (`deploy/cloudflare/README.md`) Cloudflare แพนฟรีใช้เป็น DNS/proxy หน้า Render ได้โดยไม่ต้องใช้ไฟล์ชุดนี้

5.4 โมเดลและจบ (ข้อ 4)

ร่นรวมใช้ model harness ของ Codex แทนชุดโมเดลที่ฝังไว้

เรื่อง	ในร่นรวม
Slot	โมเดลภาษา (llm), safety (guard), อ่านใบผล (vision) ค่าเริ่มต้น Typhoon <code>typhoon-v2.5-30b-a3b-instruct</code> , iApp OpenThai-SystemOne, Typhoon OCR
Agent เดิม 4 ตัว	Planner, Health-check Advisor, Report Explainer, Reviewer ใช้โมเดลภาษากลางเว้นแต่ตั้งแยก
บทบาทใหม่ 2 ตัว	Medical analyzer และ Thai composer ปิดเป็นค่าเริ่มต้น ไม่สืบทอดคีย์ ต้องระบุโมเดลตรงตัวและราคาที่ตรวจแล้ว บน OpenRouter ต้องระบุ endpoint ที่ทบทวนแล้ว และคำขอใช้ <code>allow_fallbacks: false</code> , <code>data_collection: deny</code> , <code>zdr: true</code>
สถานะ	หน้า AI providers แสดง <code>DISABLED</code> , <code>NOT_CONFIGURED</code> , <code>SCHEMA_CHECK_ONLY</code> ; การทดสอบจริงยังไม่มีบันทึก (<code>NOT_RUN</code>)
Registry	<code>runtime_skills/model_registry.json</code> เป็น metadata ของโมเดลที่พิจารณา ราคา <code>PRICE_UNVERIFIED</code> ไม่ใช่การเลือกหรือสิทธิ์เรียก
จบ	เพดานโครงการ 300 บาท ต้องระบุค่าใช้จ่ายก่อนหน้า และเพดานจำนวนครั้งต่อรอบ Codex เสนอให้ประเมินจริงในวง USD 1 เมื่อเจ้าของอนุมัติ
Embedding	เลื่อนไว้จนกว่าจะมีผลเปรียบเทียบการค้นคืน

เรื่อง	ในร่นรวม
Baseline แบบ free-first (rc2)	model_registry.json ระบุ typhoon-v2.5-30b-a3b-instruct, typhoon-ocr และ openthai-systemone เป็น BASELINE ของชุดทดสอบนี้ โมเดลอื่นเป็น DEFERRED_FOR_THIS_BENCHMARK ไม่ได้ลบ integration ของ OpenRouter

หน้า AI providers ของเว็บ Next.js ถูกปรับตามสัญญานี้: แสดง 9 ชั้น (โมเดลภาษา 6 agent safety OCR) ช่องรหัส endpoint สำหรับบทบาทใหม่ ไม่เติมราคาเริ่มต้นให้บทบาทใหม่ และนำปุ่ม "ชุดโมเดลแบบเร็ว" กับแผงความพร้อมของ Claude ออก เพราะ endpoint เหล่านั้นไม่มีใน Codex

trade-off ยังไม่มีโมเดลใดที่วัดแล้วว่าดีและถูกสำหรับงานนี้ การไม่ฝังค่าเริ่มต้นทำให้ต้องตั้งค่าเองหลัง deploy แต่ไม่มีการอ้างประสิทธิภาพที่ไม่ได้วัด

ข้อเสนอเดิมของ Claude branch (ไม่ได้ใช้ในร่นรวม) ชุด OpenRouter คีย์เดียว: planner qwen/qwen3-30b-a3b-instruct-2507, ผู้เขียนและ OCR google/gemini-3.1-flash-lite, reviewer และ safety openai/gpt-4.1-mini, embedding qwen/qwen3-embedding-8b ตรวจสอบความปลอดภัยขนานกับ planner และ reviewer ค่าประมาณ USD 0.008 ต่อคำตอบจากราคา snapshot 7 ต.ค. 2569 และงบในระบบ 360 บาท ตัวเลขเป็นสมมติฐานที่ไม่เคยวัดกับ usage จริง


5.5 หน้าเว็บภาษาไทยบน Next.js (ข้อ 5)


ร่นรวมใช้เว็บ Next.js 16 (App Router) + React 19 + React Three Fiber ของ Claude branch ภาษาไทยเป็นค่าเริ่มต้นและสลับ EN ได้ ทุกข้อความผ่าน t("English source") คำแปลไทย 2,297 รายการ (rc1 เพิ่ม 174 รายการสำหรับส่วนที่ปรับ เป็น 2,260 และ rc2 เพิ่ม 37 รายการสำหรับ harness) และ npm run i18n:check ผ่าน หน้าแรกมี DNA helix สามมิติ รายงานผลตัวอย่างที่กดดูคำอธิบายได้ และผู้ที่ตั้ง reduced motion เห็น helix แบบนี้

งานของ Claude	ในร่นรวม
Design system ฟอนต์ไทย ชิม TH/EN หน้าเว็บสาธารณะ เซตพื้นที่ลูกค้า staff desk	ใช้ตามเดิม แก้อัปเดตความเรื่องเอกสารองค์กร การเข้าสู่ระบบ และจำนวนแหล่งให้ตรง Codex
เข้าสู่ระบบพร้อม "เก็บแชตนี้"	ส่งเฉพาะ email และรหัสผ่าน ล้างหน้าจอทันที กันคำตอบเก่า
My organization	เขียนใหม่ตามสัญญา Codex บนโครงหน้าเดิม
Staff: Organizations, Reference document review	แทนด้วย Organization membership
Staff: AI providers	ปรับเป็น 3 slot + 6 agent บทบาทใหม่ปิด สถานะการตั้งค่า registry และ (rc2) แผงนโยบาย free-only กับแผง harness

งานของ Claude	ในรุ้รวม
รายละเอียด "การตรวจสอบคำตอบนี้" ได้คำตอบ	(rc2) แสดงข้อมูลที่เวิร์กเวิร์กมาใช้ (typed tools) และโมดูลคำแนะนำที่ผ่านการตรวจสอบ (runtime skills) เป็นชื่อเท่านั้น
ป้ายองค์กรในแชต	แสดงสถานะ (ใช้กับผู้ช่วย หรือค้นหาอย่างเดียว) แทนการเลือกต่อแชต
หน้าใหม่	/hospital-links และสคริปต์ start:render
Backend ของ Claude (routers/org.py , org_knowledge , keep-chat, fast profile, ตรวจสอบ, semantic search)	ไม่ได้นำมา ยังอยู่ใน release/4.0.0 ใน bundle

trade-off ระบบมีสอง runtime (Node สำหรับหน้าเว็บ Python สำหรับ API) และหน้าเว็บสองชุด (Next.js และ Jinja เดิมของ Codex) ต้องระวังไม่แก้หน้าผิดชุด หน้า Jinja ยังจำเป็นเพราะชุดทดสอบของ Codex และ landing preview ใช้หน้าเหล่านั้น





rc2 ทำตามเอกสารเสริมของเจ้าของ (LABCLEAR_FREE_FIRST_BENCHMARK_ADDENDUM_TH.md และ LABCLEAR_COURSEWORK_BENCHMARK_SPEC_TH.md) โดยต่อยอด scripts/course_eval.py และ

`scripts/offline_check.py` ส่วนที่เพิ่มอยู่ในแอปจริงที่ทำงานตอนรับข้อความ ไม่ใช่ skill ของเครื่องมือเขียนโค้ด

ส่วน	ไฟล์	ทำอะไร	ค่าเริ่มต้น
Typed tools	<code>services/agent_tools.py</code> (<code>labclear-tools-1.0.0</code>)	8 เครื่องมือ: <code>lookup_packages</code> , <code>compare_packages</code> , <code>lookup_branches</code> , <code>lookup_policies</code> , <code>retrieve_evidence</code> , <code>get_confirmed_report_rows</code> , <code>preview_booking</code> , <code>get_external_hospital_offer</code> input แบบ strict (ไม่รับฟิลด์เกิน) สิทธิ์จาก <code>reads/actions</code> ของบทบาท เวลาและขนาดผลจำกัด <code>audit</code> เก็บเฉพาะชื่อ ผล และ hash ของ argument	ใช้เสมอ (แทนการอ่านข้อมูลตรงใน pipeline)
Runtime skills เลือกตามงาน	<code>services/runtime_skills.py</code> , <code>runtime_skills/thai_health/0.3.0-offline</code>	เลือกโมดูลตามบทบาท action ใบผล ชนิดหลักฐาน และเครื่องมือที่ใช้จริง เพิ่มโมดูล <code>evidence-citation</code> , <code>package-compare</code> , <code>lay-explanation</code> , <code>scope-uncertainty</code>	ปิด (<code>RUNTIME_SKILLS_ENABLED</code>)
ภาพสังเคราะห์ผ่านการอัปโหลด	<code>services/synthetic_fixtures.py</code>	รับภาพที่ bytes ตรง SHA-256 ของชุดสังเคราะห์ที่ตรวจแล้ว เฉพาะ <code>APP_ENV=test</code> เก็บแถวที่อ่านได้ก่อนยืนยัน (<code>raw_fields</code>) แยกจากค่าที่ยืนยัน และไม่ส่งให้โมเดล	ปิด (<code>SYNTHETIC_FIXTURE_MANIFEST</code> ว่าง)
นโยบาย free-only	<code>services/free_policy.py</code> , <code>eval/policies/</code>	ทุกการเรียกต้องตรง host/path/โมเดลที่ระบุไว้ <code>VERIFIED_FREE_FOR_THIS_ACCOUNT</code> พร้อมหลักฐานไม่เกิน 7 วัน และโควตากลางต่อ run (ต่อนาที ต่อชนิด decisions เวลา) ไม่ผ่าน = หยุดแบบ fail closed ledger และ call cap ยังทำงาน	ปิด (<code>FREE_ONLY_POLICY_PATH</code> ว่าง)
ตัวรันชุดทดสอบ	<code>scripts/benchmark_labclear.py</code> , <code>eval/coursework/</code>	ชุดข้อมูล 1.0.0 (33 กรณี) แยกเฉลี่ยไว้ใน <code>rubric.json</code> ที่ scorer อ่านเท่านั้น โหมด <code>OFFLINE</code> / <code>REPLAY</code> / <code>LIVE_FREE</code> แยกชัด ผลแยก <code>execution</code> , <code>automated</code> และ <code>human verdict</code>	—
เซิร์ฟเวอร์ทดลอง LIVE_FREE	<code>scripts/live_free_server.py</code>	แอปแยกที่ใช้ DB ชั่วคราว ENV สะอาด และ preflight ต้องผ่านก่อน	ไม่ใช้กับระบบจริง

ผลที่วัดได้ (OFFLINE, ตัวแทนผู้ให้บริการ) รายละเอียดอยู่ใน `COURSEWORK_BENCHMARK_REPORT_TH.md`

เรื่อง	ผล	หลักฐาน
ชุดตามโจทย์ 10 คำถาม + 5 ภาพ + 5 safety (โปรไฟล์ C, บังคับ free-only แบบ offline)	รันครบ 20/20 ผ่านเกณฑ์ pipeline 15 ไม่ผ่าน 5 (ภาพทั้ง 5: Tesseract ที่เป็นตัวแทน OCR อ่านคำผิดบางแถวและยืนยันตามที่อ่าน จึงไม่ผ่านตามกติกา) การตรวจโดยคน PENDING_REVIEW	run G-C-free
REPLAY ของ run เดียวกัน	20/20 ผลตรงกัน (ไม่ใช่ผล live)	run G-C-replay
ปรับปรุง 1: runtime skills ตามงาน	เส้นทางที่ได้โมดูลผิดสิทธิ์หรือขาดโมดูล 5/8 → 0/8 คำสั่งยาวขึ้น (ไม่ใช่การลด token)	R1-C → R2-C, skill-route-matrix.json
ปรับปรุง 2: ภาพสังเคราะห์ผ่านการอัปโหลด	ภาพที่ไปถึงคำอธิบาย 0/5 → 5/5 ค่าอ่านตรง 88/93 เท่าเดิม	R2-C → R3-C
ปรับปรุง 3: free-only + โควตากลาง	การเรียกปลายทางเสียเงินจาก slot ค้าง 30 → 0 ค่าใช้จ่ายประมาณการ 8.8626 → 0 บาท	R3-Ctrap → R4-Ctrap
LIVE_FREE (Typhoon text/OCR + iApp จริง)	ไม่ได้รับ preflight BLOCKED: ไม่มี key ในเครื่องที่รัน นโยบาย ยังไม่มีผู้ตรวจ endpoint ทั้ง 3 FREE_STATUS_UNVERIFIED	live-free-preflight.json

ผลใน OFFLINE วัดขั้นที่ไม่ใช้โมเดล (การดึงหลักฐาน validators guard ที่ไม่ใช่โมเดล side effect และบัญชีค่าใช้จ่าย) writer ตัวแทนคัดลอกจากหลักฐาน จึงไม่บอกคุณภาพภาษาไทย ความถูกต้องทางคลินิก หรือความแม่นยำของ Typhoon OCR ไม่มีผลใดในรายงานนี้ที่เป็นการผ่านทางคลินิก

ข้อสังเกตจากการวัด: เมื่อ iApp จำกัด 20 ครั้ง/นาที guard เป็นคอขวดของเวลาตอบ และชุด regression 28 กรณีใช้ decisions แบบนับเพื่อ 330 ซึ่งเกินเพดาน 300 ต่อ run ที่เสนอ จึงต้องแบ่งรัน

7. ความปลอดภัยและความเป็นส่วนตัว

LabClear ใช้ guardrail สามแบบตามที่เรียน คือ กฎ โมเดลจัดประเภท และการตรวจในโค้ด ทุกชั้นล้มเหลวแบบปิด (fail closed)

ชั้น	สิ่งที่ป้องกัน
ขนาดข้อความ 8,000 ตัวอักษร ไฟล์ไม่เกิน 3 ไฟล์ × 3 MB rate limit 120 ครั้ง/นาที	การใช้ทรัพยากรเกินขอบเขต
cookie HttpOnly + SameSite=Strict, CSRF, ตรวจ Origin เทียบ Host หรือ TRUSTED_ORIGINS แบบตรงตัว, Google sign-in แบบ state + PKCE + nonce	คำขอข้ามไซต์และการยึดบัญชี
regex ภาษาไทย/อังกฤษก่อนเรียกโมเดล	prompt injection แบบตรง ๆ

ชั้น	สิ่งที่ป้องกัน
safety model บนข้อความ คำตอบ และเอกสาร	คำขอหรือคำตอบที่ไม่ปลอดภัย คำสั่งที่ซ่อนในภาพ
Python ตรวจ citation ค่าผลตรวจ ราคา และขอบเขตบทบาท	แหล่งอ้างอิงปลอม คำถูกเปลี่ยนราคาตัวเอง
reviewer (ตั้งเป็นโมเดลต่างตระกูลได้)	คำกล่าวที่แหล่งอ้างอิงไม่รองรับ การวินิจฉัย
การจองและชำระต้องให้ลูกค้ายืนยันและเจ้าหน้าที่ตรวจ	โมเดลลงมือเอง
เอกสารองค์กร: สมาชิกจากผู้จัดการ ผู้แก้ไขอนุมัติ แยกองค์กร ตรวจสอบประวัติ ส่งให้ผู้ช่วยเฉพาะเมื่อเปิด flag และผู้ให้บริการพร้อมและไม่ใช้ :free	ข้อมูลรั่วข้ามองค์กร เอกสารที่ถอนแล้วกลับมาใช้
บทบาทใหม่บน OpenRouter: endpoint ที่ทบทวนแล้ว ไม่สลับผู้ให้บริการ data_collection: deny, zdr	ข้อมูลไปยังผู้ให้บริการที่ไม่ได้เลือก
log ข้อผิดพลาดของผู้ให้บริการเก็บเฉพาะ slot และสถานะ HTTP	ข้อความหรือคีย์รั่วใน log
PROVIDER_NETWORK_ENABLED เพดานจำนวนครั้ง และงบ 300 บาท	ค่าใช้จ่ายบานปลาย
typed tools ตามสิทธิ์บทบาท และนโยบาย free-only (rc2)	บทบาทอ่านข้อมูลเกินหน้าที่ การเรียกปลายทางเสียเงินที่ไม่ได้ตั้งใจ

การจับคู่กับ OWASP Top 10 for LLM: LLM01 prompt injection (regex, safety model, การตรวจในโค้ด, reviewer, การอนุมัติเอกสารองค์กร), LLM02 การเปิดเผยข้อมูล (ข้อมูลแยกตามเจ้าของและองค์กร คีย์เข้ารหัสและไม่ส่งถึงเบราว์เซอร์ log แบบ metadata), LLM04 การวางยาข้อมูล (ฐานความรู้ตรวจ hash แหล่งใหม่หรือตรวจเอกสารองค์กรต้องอนุมัติ), LLM05 การจัดการผลลัพธ์ (ลบลิงก์และ HTML, DOMPurify, CSP), LLM06 การให้อำนาจเกิน (preview และการยืนยัน), LLM09 ข้อมูลผิด (citation ต้องมีจริงและรองรับคำตอบ), LLM10 การใช้ทรัพยากรไม่จำกัด (rate limit และงบ)

ด้านความเป็นส่วนตัว: ข้อมูลบัญชีเข้ารหัสทุกแถว เจ้าหน้าที่เห็นว่าลูกค้าแชร์ไบผล แต่ไม่เห็นภาพหรือค่า ข้อมูลผู้เยี่ยมชมอยู่ใน RAM และถูกลบเมื่อรีเฟรชหรือเข้าสู่ระบบ เอกสารองค์กรไม่ถูกส่งไปยังผู้ให้บริการ AI จนกว่าจะเปิด `ORG_REFERENCE_INFERENCE_ENABLED` ระบบไม่สร้าง embedding รายละเอียดอยู่ใน [safety.md](#)

8. หลักฐานการทดสอบ

การตรวจของ rc2 รันบน commit `6f41a78` และชุดเวิร์กชันซ้าบน `a4aec07` วันที่ 9 ต.ค. 2569 ใช้ข้อมูลจำลอง ฐานข้อมูลชั่วคราว ตัวแทนโมเดลและ OCR และไม่เรียกผู้ให้บริการจริง ไฟล์ผลอยู่ใน [docs/evidence/integration-4.0-rc2/](#) และผลชุดทดสอบตามโจทย์อยู่ใน [docs/evidence/free-first/](#)

การตรวจ	ผล	ใช้โมเดลจริงหรือไม่
<code>python scripts/offline_check.py pytest -q</code>	328 ผ่าน (Codex 265 + rc1 12 + rc2 51)	ไม่ (ปิดการเชื่อมต่อออก)
<code>node tests/browser/uat.cjs</code> (หน้า Jinja ของ Codex)	36/36	ไม่
<code>node tests/browser/upgrade.cjs</code> (preview, ลิงก์โรงพยาบาล, เอกสารองค์กร)	10/10	ไม่
<code>python scripts/offline_check.py evaluation</code>	60 fixture ผ่าน <code>LIVE_MODEL_EVALUATION=NOT_RUN</code>	ไม่
<code>python scripts/offline_check.py boot</code> (entrypoint ของ Render)	เริ่มและหยุดได้ ตรวจ 8 เส้นทาง	ไม่
<code>npx tsc --noEmit, npm run i18n:check, npm run build</code>	ผ่าน (ไทย 2,297 ข้อความ, 16 routes)	—
<code>node tests/uat.mjs</code> (เว็บ Next.js บน <code>next start</code> ต่อกับ API จริงผ่าน rewrite)	53/53 ไม่มี browser error บน <code>a4aec07</code>	ไม่ (<code>scripts/dev_mock_api.py</code>)
<code>node tests/uat-flags-off.mjs</code> (flag ใหม่ปิดทั้งหมด)	5/5	ไม่
<code>python scripts/benchmark_labclear.py run --mode offline --suite coursework --profile C --free-only</code>	20/20 รันครบ ผ่านเกณฑ์ pipeline 15	ไม่ (ตัวแทนผู้ให้บริการ)
<code>python scripts/benchmark_labclear.py preflight ... --policy eval/policies/free_only.example.json</code>	BLOCKED จึงไม่รัน LIVE_FREE	ไม่ (ไม่ได้ส่งคำขอใด ๆ)

51 ข้อใหม่ของ rc2 อยู่ใน `test_agent_tools.py` (15), `test_runtime_skills_select.py` (6), `test_synthetic_fixtures.py` (3), `test_free_first_harness.py` (16) และ `test_benchmark_harness.py` (11) ครอบคลุมสิทธิ์และ schema ของเครื่องมือ การเลือกโมดูล การรับภาพเฉพาะ hash ที่ตรวจแล้วใน test นโยบายและโควตา free-only การกันเฉลยไม่ให้ถึงแอป และการแยกโหมด ส่วน 12 ข้อของ rc1 ครอบคลุม `/site/*` ที่ไม่สร้าง session และไม่มีข้อมูลส่วนบุคคล การนับแหล่ง 58 รายการ flag ที่ปิดเป็นค่าเริ่มต้น ลิงก์โรงพยาบาลตาม flag การปฏิเสธ origin ที่ไม่ได้ระบุหรือใกล้เคียง (subdomain, http, port, wildcard) การยอมรับ origin ที่ระบุตรงตัวทั้งใน API ธุรกิจและการตรวจของ AI endpoint `/site/membership` ที่บอกเฉพาะบทบาทของผู้เรียกเอง และคิวแหล่งรอตรวจที่ไม่ถูกค้น

Web UAT มาจาก 51 สถานการณ์ของ Claude branch สถานการณ์ที่ทดสอบสัญญาเฉพาะของ Claude ถูกเขียนใหม่ตาม Codex (R4-03, R4-04, R4-05, R4-06, R4-07) และเพิ่ม R4-15 กับ R4-13-hospital-links rc2 เพิ่มการตรวจรายละเอียดเครื่องมือและโมดูลได้คำตอบ และแผง free-only/harness ในหน้า AI providers

ข้อสังเกต rc2 (UI-22) web UAT ส่องรอบบน 6f41a78 ได้ 52/53 เพราะหน้า /staff ของผู้ดูแลได้ 500 หนึ่งครั้ง log ของ Next.js แสดง socket hang up (ECONNRESET) ตอนส่งต่อ

/api/business/staff/notifications เราตีความว่า proxy ของ Next.js ใช้การเชื่อมต่อ keep-alive ที่ว่างอยู่ (Node ตัดที่ 5 วินาที) พร้อมกับที่ uvicorn ปิดการเชื่อมต่อว่างที่ 5 วินาทีเช่นกัน ซึ่งเป็นข้อสันนิษฐานจาก log ไม่ใช่สาเหตุที่พิสูจน์แล้ว commit a4aec07 ให้ API จำลองของ UAT เก็บการเชื่อมต่อว่างไว้ 65 วินาที แล้วผ่าน 53/53 ไม่ได้แก้โค้ดของระบบหรือ scripts/run_business.py ถ้าจะวางเว็บ Next.js หน้า API บน Render ต้องพิจารณาค่าเดียวกันกับ entypoint จริง

ข้อสังเกต การทดสอบ UI-33 ในชุดเดิมของ Codex ถอดรหัสภาพย่อก่อนที่ blob ของภาพจะโหลดเสร็จ บน Linux ชุด baseline ของ Codex (c970410) ที่ไม่ได้แก้ผ่าน 1 ใน 2 รอบ และร่นรวมไม่ผ่าน 2 ใน 2 รอบ การรันที่ใส่ log ยืนยันว่าภาพโหลดได้หลังจากนั้นเล็กน้อย จึงแก้เฉพาะการทดสอบให้ร้อ blob (commit c8f3547) ไม่ได้แก้โค้ดของระบบ

ผลของ rc1 (ไม่ใช่ผลของ rc2) บน commit c8f3547: pytest 277, browser 36/36 และ 10/10, web UAT 53/53 และ 5/5 อยู่ใน integration-4.0-rc1

ผลของ Claude branch 4.0.0 (ไม่ใช่ผลของร่นรวม) บน commit 95bf3d7: pytest 261 ผ่าน (backend ของ Claude ที่ไม่ได้นำมา), UAT 51/51 บน OpenNext production build ผ่าน wrangler dev, opennextjs-cloudflare build และ wrangler deploy --dry-run ทั้งสอง worker ผล UAT 49/51 ที่เคยเขียนในรายงานฉบับก่อนเป็นของรอบก่อนแก้ UI-21 และ UI-22

สิ่งที่ยังไม่ได้ทดสอบ ยังไม่ได้เรียกผู้ให้บริการ AI จริง จึงยังรู้คุณภาพภาษาไทย ความถูกต้องของ JSON และ OCR ความเร็ว และราคาจริงของรุ่นนี้ ยังไม่ได้สร้างบริการเว็บบน Render ยังไม่ได้ต่อ PostgreSQL ของระบบจริง ยังไม่ได้ทดสอบบนมือถือจริงและ screen reader ชุดทดสอบของวิชา (คำถาม 10 ข้อ ภาพ 5 ภาพ ความปลอดภัย 5 กรณี) แบบ live ต้องรันด้วย scripts/benchmark_labclear.py --mode live-free เมื่อ preflight ผ่าน ตาม FREE_PROVIDER_PREFLIGHT.md และให้คนตรวจทุกกรณี holdout 5 กรณียังไม่ได้รัน

ผลรอบจริงครั้งแรกเมื่อ 7 ต.ค. บนรุ่น 3.0 (คำถามผ่าน 7/10 ภาพ 4/5 ความปลอดภัย 5/5) รอบ 2 และรอบ 3 (Typhoon บน Render) บันทึกไว้ใน testing.md เป็นหลักฐานของรุ่นก่อน รอบที่ 4 บนรุ่น 3.0.2 ถูกหยุดด้วยเพดานจำนวนครั้ง จึงไม่มีผลคุณภาพ

9. การดำเนินงาน

เรื่อง	วิธี
ตรวจรับ	นำเข้า bundle ตรวจ diff และผลทดสอบ แล้วเจ้าของ merge เข้า <code>main</code> เอง (ไม่มีการ push จากงานนี้)
Deploy API	Render deploy บริการ <code>labclear</code> ตาม <code>render.yaml</code> เดิม ไม่ต้องเพิ่มคีย์ใหม่ flag ใหม่ยังปิด
Deploy เว็บ (เลือกได้)	ตาม <code>deploy/render-web.md</code> แล้วเจ้าของตั้ง <code>TRUSTED_ORIGINS</code> ที่ API
ตรวจสอบสถานะ	<code>/health</code> แสดง <code>version</code> 4.0.0-rc2 และ <code>commit</code> ของทั้งสองบริการ
ประเมินแบบ free-first	ตาม <code>FREE_PROVIDER_PREFLIGHT.md</code> : กรอกรายละเอียดที่ตรวจแล้ว ใส่ key ใน shell ของเครื่องที่รันเท่านั้น รัน preflight แล้ว smoke และชุดตามโจทย์บน <code>scripts/live_free_server.py</code> ไม่ใช้บริการจริงและไม่แก้ ENV ของ Render
คุมงบ	<code>PROVIDER_NETWORK_ENABLED</code> , <code>CLOUD_CALL_LIMIT</code> ต่อ <code>PROVIDER_BUDGET_CYCLE_ID</code> , <code>PROJECT_BUDGET_THB=300</code> , <code>PROJECT_BUDGET_PRIOR_SPEND_THB</code> ยอดดูได้ที่ <code>/staff</code> → Channels and budget
เปิดความ สามารถใหม่	ที่ละ flag ตาม <code>MORNING_HANDOFF</code> และ <code>ENV_HANOVER</code>
ย้อนรุ่น	ปิด flag ก่อน ถ้าต้องย้อนโค้ด ให้เลือก deploy ก่อนหน้านั้นบน Render หรือ revert commit ห้าม force-push ห้ามรีเซ็ตฐานข้อมูล คีย์ หรือยอดใช้จ่าย
ปัญหาที่คาบไว้	403 <code>origin_rejected</code> ผ่านเว็บ = <code>TRUSTED_ORIGINS</code> ไม่ตรง origin ของเว็บ; หน้าเว็บแสดงข้อมูล seed = API ยังหลับ; AI ไม่ตอบ = <code>PROVIDER_NETWORK_ENABLED</code> หรือรอบงบยังไม่ตั้ง

10. ข้อจำกัดและงานต่อไป

ข้อจำกัด

- คุณภาพ ความเร็ว และราคาของโมเดลยังไม่ได้วัดกับรุ่นนี้ (LIVE_FREE ยังไม่ได้รัน ผล OFFLINE เป็นของตัวแทนผู้ให้บริการ)
- เพดาน 300 decisions ต่อ run ไม่พอชุด regression 28 กรณี (ต้องการ 330) และโควตา iApp 20 ครั้ง/นาที ทำให้ guard เป็นคอขวด
- ตัวแทน OCR ใน OFFLINE คือ Tesseract คะแนนอ่านภาพจึงไม่ใช่ของ Typhoon OCR
- rate limit ของ API นับตาม IP ที่ต่อเข้ามา ผู้ใช้ผ่านบริการเว็บจึงใช้ bucket เดียวกัน (120 ครั้ง/นาที)
- Google sign-in ผ่านบริการเว็บยังไม่ได้ทดสอบ
- API มี instance เดียว เซตผู้เยี่ยมชมหายเมื่อ restart และแผนฟรีของ Render หลับเมื่อไม่มีการใช้งาน
- ฐานที่ค้นยังมี 4 ผู้เผยแพร่ แหล่งใหม่ 111 รายการรอตรวจ
- เอกสารองค์กรรับเฉพาะ TXT/MD และค้นด้วยการจับคู่คำ ไม่รองรับ PDF, DOCX หรือ OCR

- ข้อมูลธุรกิจและผลตรวจเป็นข้อมูลจำลอง ระบบให้ข้อมูลสุภาพทั่วไป ไม่วินิจฉัยโรค

งานต่อไป

1. เจ้าของตรวจรับ bundle merge แล้ว deploy บน Render ตรวจ `/health`
2. สร้างบริการเว็บและตั้ง `TRUSTED_ORIGINS` แล้วตรวจรับตามคู่มือ
3. ออกแบบการนับ rate limit ผ่านบริการเว็บ และทดสอบ Google sign-in
4. ยืนยันสิทธิ์ฟรีของบัญชีและ endpoint แล้วรัน LIVE_FREE ตาม runbook เก็บผลดิบ ให้คนตรวจทุกกรณี และรัน holdout ครั้งแรกหลังปรับเสร็จ
5. ตรวจแหล่งความรู้ที่รอ แล้วย้ายเฉพาะที่ผ่านเข้า `catalog.json`
6. เปิด flag ใหม่ทีละตัวตามประตูของเจ้าของ
7. ทดสอบบนมือถือจริงและ screen reader

ภาคผนวก ก. Endpoint ที่เว็บ Next.js ใช้และที่เพิ่มในรุ่นรวม

Method	Path	ใช้ทำอะไร
POST	<code>/api/business/login</code> , <code>/register</code>	email และรหัสผ่านเท่านั้น แชนด์ผู้เยี่ยมชมของหน้านั้นถูกลบ
POST	<code>/api/business/guest/close</code>	beacon ลบแชนด์ผู้เยี่ยมชมเมื่อปิดหรือรีเฟรชหน้า
GET	<code>/api/business/site/common</code> , <code>/site/home</code> , <code>/site/sources</code> , <code>/site/packages/{id}</code> , <code>/site/compare</code>	ข้อมูลสาธารณะสำหรับหน้าเว็บ ไม่มี session และข้อมูลส่วนบุคคล (เพิ่มในรุ่นรวม)
GET	<code>/api/business/site/features</code> , <code>/site/hospital-links</code>	flag แบบ true/false และลิงก์โรงพยาบาล (เพิ่มในรุ่นรวม)
GET	<code>/api/business/site/membership</code>	บทบาทองค์กรของผู้เรียกเอง (เพิ่มในรุ่นรวม)
GET, POST	<code>/api/business/organization-documents</code> , <code>/search</code>	รายการ อับโหลดร่าง และค้นข้อความต้นฉบับ (Codex)
GET, POST	<code>/api/business/organization-documents/{id}</code> , <code>{id}/download</code> , <code>{id}/{approve, reject, revoke, delete}</code>	ดูตัวอย่าง ดาวน์โหลด และเปลี่ยนสถานะ (Codex)
PUT	<code>/api/business/organization-documents/membership</code>	ผู้จัดการกำหนดสมาชิก (Codex)

Method	Path	ใช้ทำอะไร
GET, PUT, DELETE, POST	/api/business/staff/ai-providers, /registry, /{slot}, /{slot}/test	ผู้จัดการตั้งผู้ให้บริการ ดู registry และ ทดสอบ 1 ครั้ง (Codex)

รายการเต็มอยู่ใน [api.md](#)

ภาคผนวก ข. ค่าตั้งที่สำคัญ

ค่า	ค่าเริ่มต้น	ความหมาย
LANDING_PREVIEW_ENABLED, ORG_DOCUMENTS_ENABLED, ORG_REFERENCE_INFERENCE_ENABLED, HOSPITAL_LINKS_ENABLED, RUNTIME_SKILLS_ENABLED, MEDICAL_HARNESS_ENABLED	false	ความสามารถใหม่ของ Codex เปิด ทีละตัวหลังผ่านประตูของเจ้าของ
TRUSTED_ORIGINS	ว่าง	origin ของบริการเว็บที่ API ยอมรับ (เพิ่มในรุ่นรวม)
LLM_PROVIDER, GUARD_PROVIDER, VISION_PROVIDER	typhoon, iapp_system one, typhoon_ocr	ผู้ให้บริการสำรองจาก environment ค่าที่บันทึกในหน้า AI providers มีลำดับเหนือกว่า
VISION_ENABLED	false	การอ่านใบผลด้วย OCR
PROVIDER_NETWORK_ENABLED	false	การเรียกผู้ให้บริการทั้งหมด
PROVIDER_BUDGET_CYCLE_ID, CLOUD_CALL_LIMIT	ว่าง, 200	รอบและเพดานจำนวนครั้ง
PROJECT_BUDGET_THB, PROJECT_BUDGET_PRIOR_SPEND_THB	300, ว่าง	งบรวมของโครงการและยอดที่ใช้ ก่อนหน้านี้ (ว่าง = ไม่ให้เรียกแบบมี ค่าใช้จ่าย)
DATABASE_URL, BUSINESS_DATA_KEY	—	ต้องมีบนระบบที่ host ห้ามหมุนคีย์ โดยไม่ย้ายข้อมูล
API_ORIGIN (บริการเว็บ)	http://127. 0.0.1:8000	URL ของบริการ API ที่เว็บส่งต่อ /api
FREE_ONLY_POLICY_PATH, FREE_ONLY_RUN_ID	ว่าง	นโยบาย free-only และรหัส run ของโควตา (rc2 ใช้กับเซิร์ฟเวอร์ ทดลอง)

ค่า	ค่าเริ่มต้น	ความหมาย
FREE_ONLY_ALLOW_OFFLINE_DOUBLES	false	ยอมรับรายการ OFFLINE_DOUBLE ในนโยบาย เฉพาะ OFFLINE
SYNTHETIC_FIXTURE_MANIFEST	ว่าง	รายการ hash ของภาพสังเคราะห์ ที่รับผ่านการอัปโหลด ใช้ได้เฉพาะ APP_ENV=test

ค่าทั้งหมดอยู่ใน config.py และ ENV_HANOVER ค่าที่ผู้จัดการบันทึกในหน้า AI providers มีลำดับเหนือ environment ยกเว้นบทบาทใหม่ที่ไม่มีค่าสำรองจาก environment